

Статистика для Data Science

План от простого к сложному и проверенные источники на русском и английском, с упором на Python

Уровень: курс «Статистика для Data Science» в магистратуре. Подходит и тем, кто пришёл в DS из программирования: недостающая математика собрана в этапе 0, у каждого источника указаны уровень сложности и что нужно знать заранее.

Темы: описательная статистика и EDA · теория вероятностей · ЗБЧ и ЦПТ · оценивание и доверительные интервалы · проверка гипотез · сравнение групп · регрессия · A/B-тесты · временные ряды · причинный вывод · байесовская статистика · статистика в оценке ML-моделей.

Сверено: набор тем сопоставлен с программами MIT, Stanford, Harvard, CMU, Columbia и Berkeley (раздел 4); ссылки проверены в сентябре 2026.

1

Как работать ······ 1

4

Сравнение с университетами ······ 6

7

Вводное чтение и ключи ······ 13

2

План: этапы 0–9 ······ 2

5

Термины RU ↔ EN ······ 7

3

Важные темы для DS & AI ······ 5

6

Источники ······ 9

1 Как работать

Этапы идут сверху вниз; каждый проходите по одному циклу — источники для всех шагов уже подобраны в карточках.

1

Интуиция
Видео на 10–20 минут — понять идею.
StatQuest, Карпов

→

2

Теория
Определения по учебнику, на русском и английском.
Лагутин, OpenIntro

→

3

Код
Повторить расчёты и симуляции в Python.
Think Stats, MatStat-AB

→

4

Задачи
5–10 задач со сверкой ответов.
MIT 18.05, OpenIntro, Лагутин

→

5

Проверь себя
Вопрос из карточки и свой глоссарий RU ↔ EN.
ключи — в конце файла

Пример — этап 4 (доверительные интервалы): 1 StatQuest «Confidence Intervals» → 2 Лагутин, OpenIntro гл. 12 → 3 MatStat-AB нед. 8, `scipy.stats.bootstrap` → 4 задачи Коршунова и Черновой → 5 «что означает 95%-й ДИ?»

Карта этапов этапы 1–9 ≈ 14–18 недель при 5–6 часах в неделю



Основной комплект ★ этого достаточно, чтобы пройти весь план; остальное — по необходимости

ИНТУИЦИЯ

★ Карпов «Основы статистики», ч. 1
●○○○ вводный RU
бесплатно

★ StatQuest
●○○○ вводный EN
бесплатно

ТЕОРИЯ

★ Лагутин «Наглядная математическая статистика»
●○○○ средний RU
задачи

★ OpenIntro «Introduction to Modern Statistics»
●○○○ базовый EN
бесплатно

КОД

★ Think Stats, 3-е изд.
●○○○ базовый EN Py
бесплатно

★ MatStat-AB (Ульянкин)
●○○○ средний RU Py
бесплатно

ЗАДАЧИ

★ MIT 18.05
●○○○ средний EN
решения бесплатно

+ задачи Лагутина и упражнения OpenIntro

Уровни сложности источников

учитывают математику, глубину и то, что нужно знать заранее

●○○○ **вводный**

без высшей математики: интуиция, картинки, примеры.

●●○○ **базовый**

школьная алгебра и немного кода; формулы без доказательств.

●●●○ **средний**

нужны производные, интегралы и основы теорвера; выводы формул.

●●●● **продвинутый**

строгие доказательства; уверенные матанализ, линейная алгебра и теорвер.

Правила

- Параллельно с университетским курсом план работает как карта: найдите тему лекции среди этапов и берите материалы из карточки.
- Определения — только из учебников, не из блогов и научпопа. Если формулировки расходятся, сверьте русский и английский учебник (подсказки — в разделе 5).
- Уровень источника — под свою подготовку. Если математики не хватает, начните с этапа 0 и источников базового уровня; строки «Глубже» при первом проходе можно пропустить.
- Не нужно проходить всё: на каждый шаг цикла достаточно одного источника; ○ — запасные варианты.
- После каждого блока — мини-проект в Jupyter на реальных данных: I — разведочный анализ датасета; II — сравнение групп (размер эффекта, ДИ, p-value); III — регрессия или прогноз с честной валидацией.

Метки: **RU** **EN** язык · **Py** **R** код · **задачи** упражнения · **решения** с ответами · **бесплатно** **платно*** · ★ основной комплект · ○ дополнительно

2 План по этапам

В карточке — темы этапа и шаги цикла; строка «Глубже» — университетский уровень строгости, при первом проходе её можно пропустить. Главы указаны для изданий из раздела 6; названия источников и номера глав — кликабельные ссылки.

0 Подготовка — по необходимости: если математика подзабылась или вы пришли из программирования

0 Математика и Python для статистики

по необходимости

темы производные (в том числе логарифма и частные), интегралы как площадь под кривой, суммы и знак Σ ; векторы, матрицы и их умножение; Python для данных: NumPy, pandas, графики.

интуиция 3Blue1Brown: [Essence of calculus](#), [Essence of linear algebra](#) (видео)

теория [Хендбук Яндекса](#), гл. 3 (матанализ) и [гл. 4](#) (линейная алгебра)

код [McKinney «Python for Data Analysis»](#), 3-е изд. — бесплатно онлайн

чтение научно-популярные книги для первого знакомства — раздел 7

✓ **Проверь себя:** найдите p , при котором $L(p) = p^3(1-p)^7$ максимальна (через производную $\ln L$), и умножьте матрицу 2×3 на вектор из трёх чисел.

I Фундамент — язык описания данных и вероятности

1 Описательная статистика и EDA

≈ 1–2 нед.

темы типы данных и шкалы; среднее, медиана, мода, квантили; дисперсия, стандартное отклонение, размах и IQR, выбросы; гистограмма и boxplot; ковариация, корреляция Пирсона и Спирмена; корреляция $\neq$ причинность.

интуиция [Карпов, ч. 1](#) (описательные статистики, корреляция) · StatQuest: [Histograms](#), [Boxplots](#), [Why Dividing by N Underestimates the Variance](#), [Covariance](#), [Pearson's Correlation](#)

теория [Think Stats](#), гл. 1, 2, 7 · [OpenIntro](#), гл. 4–5 · [Брюс](#), гл. 1 — как те же понятия называют в DS

код [MatStat-AB](#), нед. 2, 4 · pandas: `describe()`, `corr(method="spearman")`

задачи [OpenIntro](#), гл. 4–5 (ответы к нечётным) · упражнения Think Stats

✓ **Проверь себя:** может ли корреляция Пирсона быть ≈ 0 при сильной зависимости? Приведите пример.

2 Теория вероятностей

≈ 2–3 нед.

ТЕМЫ вероятность, условная вероятность, формула Байеса, независимость; случайные величины, функция распределения, плотность; матожидание, дисперсия и ковариация случайных величин и их свойства; распределения: Бернулли, биномиальное, Пуассона, равномерное, экспоненциальное, нормальное.

ИНТУИЦИЯ StatQuest: [Conditional Probability, Bayes' Theorem, Expected Values](#) · [Seeing Theory](#), гл. 1–3

ТЕОРИЯ [Хендбук Яндекса](#), гл. 6 (с кодом на Python) · [Чернова](#) «Теория вероятностей» · [Stat 110](#) или [STAT 414](#)

КОД [Think Stats](#), гл. 3, 4, 5, 6 · `scipy.stats`: `norm`, `binom`, `poisson` → `.pmf/.pdf`, `.cdf`, `.rvs`

ЗАДАЧИ [MIT 18.05](#) (задания с решениями) · [Гмурман](#), части про события и случайные величины · тесты [Stepik 182381](#)

ГЛУБЖЕ  совместные распределения и многомерное нормальное, производящие функции моментов, неравенства Маркова и Чебышёва — [Stat 110](#), [STAT 414](#), [Чернова](#)

✓ **Проверь себя:** чем независимость случайных величин отличается от некоррелированности?

3 ЗБЧ, ЦПТ и выборочные распределения

≈ 1 нед.

ТЕМЫ генеральная совокупность и выборка; закон больших чисел; центральная предельная теорема; выборочное распределение статистики, стандартная ошибка; распределения χ^2 , Стьюдента, Фишера.

ИНТУИЦИЯ StatQuest: [The Central Limit Theorem, Standard Deviation vs Standard Error](#) · [Seeing Theory](#), гл. 3

ТЕОРИЯ [Лагутин](#) · [Брюс](#), гл. 2 · [Think Stats](#), гл. 8 (начало)

КОД [MatStat-AB](#), нед. 5 · симуляция ЦПТ: `np.random.default_rng()` → гистограмма выборочных средних

ЗАДАЧИ [MIT 18.05](#) (задачи на ЦПТ) · задачи Лагутина

✓ **Проверь себя:** чем стандартное отклонение отличается от стандартной ошибки?

II Статистический вывод — как по выборке делать выводы о генеральной совокупности

4 Оценивание и доверительные интервалы

≈ 2 нед.

ТЕМЫ точечные оценки и их свойства: несмещённость, состоятельность, эффективность; метод моментов, метод максимального правдоподобия (ММП); доверительные интервалы для среднего, доли, разности; бутстрэп.

ИНТУИЦИЯ StatQuest: [Maximum Likelihood, Confidence Intervals, Bootstrapping](#) · [Seeing Theory](#), гл. 4

ТЕОРИЯ [Лагутин](#) · [Чернова](#) «Математическая статистика» · [STAT 415](#) (оценивание и ДИ)

КОД [MatStat-AB](#), нед. 6, 7, 8, 10, 12 · [Think Stats](#), гл. 8 · `scipy.stats.bootstrap`

ЗАДАЧИ [Коршунов](#), [Чернова](#) · [OpenIntro](#), гл. 12 · [MIT 18.05](#)

ГЛУБЖЕ  достаточные статистики, информация Фишера и неравенство Рао–Крамера, асимптотическая нормальность оценок ММП, дельта-метод — [Чернова](#), [YAMC](#) (темы 5–7), [Wasserman](#), гл. 9

✓ **Проверь себя:** что именно означает «95%-й доверительный интервал»? Почему про уже построенный интервал неверно говорить «параметр лежит в нём с вероятностью 95%»?

5 Проверка гипотез

≈ 2 нед.

ТЕМЫ H_0 и H_1 , статистика критерия, уровень значимости α , p-value; ошибки I и II рода, мощность, размер эффекта; z- и t-критерии (Стьюдента, Уэлча, парный); непараметрические: Манна–Уитни, перестановочные тесты; множественные сравнения: Бонферрони, Холм, FDR.

ИНТУИЦИЯ StatQuest: [Hypothesis Testing, p-values, p-hacking, Statistical Power, FDR](#) · [Карпов](#), ч. 1

ТЕОРИЯ [Лагутин](#) · [OpenIntro](#), гл. 11, 13–14, 19–21 · [STAT 415](#) (гипотезы, непараметрика)

КОД [MatStat-AB](#), нед. 9, 10 · [Think Stats](#), гл. 9 · `ttest_ind(a, b, equal_var=False)` — тест Уэлча; `multipletests` (`statsmodels`)

ЗАДАЧИ [OpenIntro](#), гл. 11–21 · [Коршунов](#), [Чернова](#) · [MIT 18.05](#)

ГЛУБЖЕ  лемма Неймана–Пирсона, тест отношения правдоподобия, критерий Вальда — [YAMC](#) (тема 12), [Wasserman](#), гл. 10, [MIT 18.650](#) (лекции 7–10)

✓ **Проверь себя:** почему p-value — не вероятность того, что H_0 верна?

6 Несколько групп и таблицы сопряжённости

≈ 1 нед.

ТЕМЫ дисперсионный анализ (ANOVA) и попарные сравнения после него; критерий Краскела–Уоллиса; χ^2 -критерии независимости и согласия; точный тест Фишера.

ИНТУИЦИЯ [Карпов, ч. 1](#) (ANOVA) и [ч. 2](#) (номинативные данные, непараметрика) · StatQuest: [t-tests and ANOVA](#)

ТЕОРИЯ [Брюс](#), гл. 3 · [OpenIntro](#), гл. 18, 22 · [STAT 415](#) (χ^2 -критерии)

КОД [MatStat-AB](#), нед. 10 (критерии согласия) · `scipy.stats: f_oneway, kruskal, chi2_contingency, fisher_exact`

ЗАДАЧИ [OpenIntro](#), гл. 18, 22

✓ **Проверь себя:** почему нельзя сравнить пять групп попарными t-тестами без поправки?

III Модели и применение — регрессия, эксперименты, временные ряды

7 Регрессия

≈ 2 нед.

ТЕМЫ МНК; интерпретация коэффициентов, R^2 ; значимость коэффициентов и корреляции; категориальные признаки; диагностика: остатки, гетероскедастичность, мультиколлинеарность; логистическая регрессия, отношение шансов.

ИНТУИЦИЯ StatQuest: [Linear Regression](#), [R-squared](#), [Logistic Regression](#), [Odds Ratios](#) · [Карпов, ч. 1](#) (корреляция и регрессия)

ТЕОРИЯ [ISLP](#), гл. 3–4 · [Think Stats](#), гл. 10, 11 · [Брюс](#), гл. 4

КОД [MatStat-AB](#), нед. 13 · лабораторные [ISLP](#) · `statsmodels: smf.ols, smf.logit`

ЗАДАЧИ [ISLP](#), упражнения гл. 3–4 · [OpenIntro](#), гл. 7–9, 24–26

ГЛУБЖЕ  обобщённые линейные модели (GLM), регуляризация (ridge, lasso), выбор модели — [ISLP](#), гл. 4 и 6, [MIT 18.650](#) (лекции 21–24)

✓ **Проверь себя:** почему значимый коэффициент регрессии — ещё не причинный эффект?

8 A/B-тесты и дизайн экспериментов

≈ 1–2 нед.

ТЕМЫ рандомизация и контрольная группа; выбор метрики; мощность, MDE и размер выборки; «подглядывание» (peeking); метрики-отношения (дельта-метод, линеаризация); снижение дисперсии (CUPED); множественное тестирование в экспериментах.

ИНТУИЦИЯ StatQuest: [Power Analysis](#) · [Брюс](#), гл. 3 (A/B-тесты, мощность и размер выборки)

ТЕОРИЯ [Кохави, Тан, Сюй](#) «Доверительное A/B-тестирование»

КОД [MatStat-AB](#), нед. 11 · [YAMC](#), темы 8–9 и 14 (асимптотический A/B, метрики-отношения, CUPED) · `statsmodels.stats.power`

ЗАДАЧИ домашние задания [YAMC](#)

✓ **Проверь себя:** почему нельзя остановить тест, как только p-value опустилось ниже 0,05?

9 Временные ряды · отдельный трек

≈ 2–3 нед.

ТЕМЫ тренд, сезонность, декомпозиция; автокорреляция (ACF, PACF); стационарность, белый шум; простые прогнозы (наивный, сезонный наивный) как точка отсчёта; экспоненциальное сглаживание (ETS), ARIMA; валидация по времени, метрики MAE, RMSE, MASE; интервалы прогноза; ложная корреляция рядов с трендом. Можно начинать сразу после этапа 7.

ИНТУИЦИЯ [Think Stats](#), гл. 12 — мягкое введение

ТЕОРИЯ [FPP, the Pythonic Way](#), гл. 1–5, 7–9 · [Нильсен](#) (на русском; R и Python)

КОД FPP (statsforecast) · [MatStat-AB](#), нед. 14, 15 · `statsmodels.tsa: acf, adfuller`

ЗАДАЧИ упражнения в конце глав [FPP](#)

✓ **Проверь себя:** почему для временного ряда нельзя делать обычную кросс-валидацию с перемешиванием?

3 Ещё важные темы для DS & AI

Их часто нет в базовых курсах статистики, но в работе они нужны постоянно. Подключайте параллельно основному плану.

А Причинный вывод (causal inference)

после этапов 7–8

- ЗАЧЕМ** в DS часто спрашивают «что будет, если изменить X?», а корреляция и регрессия сами на это не отвечают.
- ТЕМЫ** конфаундеры, парадокс Симпсона; рандомизация как «золотой стандарт»; разность разностей (diff-in-diff), мэтчинг и propensity score, инструментальные переменные.
- ГДЕ** [Facure](#) «Causal Inference for the Brave and True», ч. I (Python) · [YAMC](#), тема 14 (ATE, uplift) · [OpenIntro](#), гл. 3 (парадокс Симпсона) · глубже — [Wasserman](#), гл. 16

✓ **Проверь себя:** что такое конфаундер? Приведите пример парадокса Симпсона.

Б Байесовская статистика

после этапа 4

- ЗАЧЕМ** другой взгляд на неопределённость; основа байесовских A/B-тестов и вероятностных моделей в ML.
- ТЕМЫ** априорное и апостериорное распределения, правдоподобие; сопряжённые априорные; байесовский интервал; основы MCMC.
- ГДЕ** [Think Bayes](#), 2-е изд. (Python) · [MatStat-AB](#), нед. 16 · [Дэвидсон-Пайлон](#) (PyMC, есть перевод) · [Seeing Theory](#), гл. 5 · глубже — [Wasserman](#), гл. 11

✓ **Проверь себя:** чем байесовский интервал (credible) отличается от доверительного (confidence)?

В Статистика в оценке ML-моделей

вместе с курсами по ML

- ЗАЧЕМ** метрика модели на тесте — тоже случайная величина: без ДИ и корректного сравнения легко «найти» улучшение, которого нет.
- ТЕМЫ** смещение и разброс (bias-variance); кросс-валидация и бутстрэп; ДИ для метрик; сравнение моделей (парные тесты, критерий Мак-Немара); утечки данных; связь ММП и функций потерь ($MSE \leftrightarrow$ нормальный шум, $\log\text{-loss} \leftrightarrow$ правдоподобие Бернулли); энтропия и KL-дивергенция.
- ГДЕ** [ISLP](#), гл. 5 и 13 · [MatStat-AB](#), нед. 13 (функции потерь из ММП) · [Raschka](#) (2018), обзор методов оценки и сравнения моделей · StatQuest: [Bias and Variance](#), [Cross Validation](#), [Entropy](#) · [Хендбук Яндекса](#), гл. 6 (информационные меры)

✓ **Проверь себя:** как получить доверительный интервал для ассурасы модели на тестовой выборке?

+ Для углубления после плана, по желанию

- [Wasserman «All of Statistics»](#) — весь матстат сжато и строго; удобен как справочник.
- [Casella, Berger «Statistical Inference»](#) — строгая теория статистического вывода.
- [Hastie, Tibshirani, Friedman «The Elements of Statistical Learning»](#) — после ISLP.
- [YAMC](#), темы «Про»: виды сходимости, ЦПТ без характеристических функций, лемма Неймана–Пирсона.

4 Сравнение с программами университетов

Темы плана сопоставлены с официальными описаниями и программами курсов статистики в сильных университетах (данные на сентябрь 2026). Для каждого университета взято ядро по статистике; названия столбцов — ссылки на программы.

ТЕМА	Этот план этапы 0–9, А–В	MIT 18.05 + 18.650	Stanford MS Stat: DS — 200, 203, 202, 209/263	Harvard Stat 110 + 111	CMU 36-705	Columbia MS DS — GR5701–5703	Berkeley Data 100
1 Описательная статистика, EDA	●	○	○	○	—	●	●
2 Теория вероятностей	●	●	○	●	○	●	○
3 ЗБЧ, ЦПТ, выборочные распределения	●	●	●	●	●	●	○
4 Оценивание, ММП, ДИ, бутстрэп	●	●	●	●	●	●	●
5 Проверка гипотез, множественные сравнения	●	●	●	●	●	●	○
6 ANOVA, χ^2 -критерии, непараметрика	●	●	●	—	○	—	—
7 Регрессия (линейная, логистическая, GLM)	●	●	●	○	●	●	●
8 A/B-тесты, дизайн экспериментов	●	—	○	—	—	○	—
9 Временные ряды	●	—	—	—	—	○	—
А Причинный вывод	●	—	○	○	○	—	—
Б Байесовская статистика	●	●	●	●	●	●	—
В Статистика в ML: bias–variance, CV	●	—	●	○	○	—	●
+ Строгая теория: Фишер, асимптотика, LRT	○	●	●	●	●	○	—

● есть в программе · ○ частично, кратко или курс по выбору · ○ пререквизит — изучают до курса · — нет в описании (часто — отдельный курс)

Выводы

- **Ядро совпадает.** Оценивание, доверительные интервалы, проверка гипотез, регрессия и байесовский подход есть почти во всех программах — в плане это этапы 3–5, 7 и тема Б.
- **Теорвер — фундамент.** В Stanford и CMU он пререквизит, в MIT, Harvard и Columbia — первый курс (18.05, Stat 110, GR5701). В плане это этап 2, его не стоит пропускать.
- **Университеты глубже в теории.** Информация Фишера, асимптотика ММП, тест отношения правдоподобия и лемма Неймана–Пирсона — стандарт MIT 18.650, Stanford STATS 200, Harvard Stat 111 и CMU 36-705. В плане это строки «Глубже» в этапах 2, 4, 5, 7 и «Углубление».
- **DS-программы добавляют практику:** EDA и визуализацию (Columbia GR5702, Berkeley Data 100), statistical learning (Stanford STATS 202, Data 100), причинный вывод или планирование экспериментов (Stanford STATS 209 или 263). В плане это этапы 1, 8 и темы А, В.
- **A/B-тесты и временные ряды** в ядро статистики обычно не входят: это отдельные курсы или части прикладных (Columbia GR5703 упоминает дизайн экспериментов и данные, зависящие от времени). В плане они вынесены в этапы 8–9, потому что постоянно нужны в работе.

Программы: MIT 18.05 · MIT 18.650 · Stanford: ядро MS Stat: DS · STATS 200 · STATS 203 · Harvard Stat 111 · CMU 36-705 · Columbia MS DS · Columbia GR5701–5703 · GR5703, весна 2026 · Berkeley Data 100. Отметки сделаны по официальным описаниям и программам курсов: «нет в описании» не значит, что тему никогда не упоминают на лекциях.

5 Термины RU ↔ EN

Словарь по этапам плана — 102 пары. Заведите свой глоссарий и дополняйте его по ходу; ниже словаря — места, где чаще всего путаются.

1 Данные и описательная статистика

генеральная совокупность	population
выборка; объём выборки	sample; sample size
наблюдение	observation
признак, переменная	feature, variable
количественный / категориальный признак	numerical / categorical variable
порядковая шкала	ordinal scale
среднее (арифметическое)	mean
медиана; мода	median; mode
квантиль; перцентиль; квартиль	quantile; percentile; quartile
размах	range
межквартильный размах	interquartile range (IQR)
дисперсия; стандартное отклонение	variance; standard deviation
коэффициент вариации	coefficient of variation
выброс	outlier
асимметрия; эксцесс	skewness; kurtosis
ящик с усами (диаграмма размаха)	box plot
диаграмма рассеяния	scatter plot
ковариация; коэффициент корреляции	covariance; correlation coefficient
ранговая корреляция Спирмена	Spearman's rank correlation

2 Вероятность

пространство элементарных исходов	sample space
случайное событие	random event
условная вероятность	conditional probability
формула полной вероятности	law of total probability
формула Байеса	Bayes' theorem
независимость	independence
случайная величина	random variable
дискретная / непрерывная	discrete / continuous
функция распределения	cumulative distribution function (CDF)
плотность распределения	probability density function (PDF)
ряд распределения	probability mass function (PMF)
математическое ожидание	expected value, expectation
совместное / маргинальное распределение	joint / marginal distribution
нормальное (гауссово) распределение	normal (Gaussian) distribution
показательное (экспоненциальное) распределение	exponential distribution
производящая функция моментов	moment generating function (MGF)

3-4 Выборочные распределения и оценивание

закон больших чисел	law of large numbers (LLN)
центральная предельная теорема	central limit theorem (CLT)

сходимость по вероятности / по распределению	convergence in probability / in distribution
параметр; статистика (функция выборки)	parameter; statistic
точечная / интервальная оценка	point / interval estimate
смещение; несмещённость	bias; unbiasedness
состоятельность	consistency
эффективность	efficiency
среднеквадратичная ошибка	mean squared error (MSE)
метод моментов	method of moments
метод максимального правдоподобия (ММП)	maximum likelihood estimation (MLE)
функция правдоподобия	likelihood function
информация Фишера	Fisher information
число степеней свободы	degrees of freedom
уровень доверия (доверительная вероятность)	confidence level
бутстрэп	bootstrap

5-6 Проверка гипотез и сравнение групп

нулевая / альтернативная гипотеза	null / alternative hypothesis
статистика критерия	test statistic
критическая область	critical (rejection) region
односторонний / двусторонний критерий	one-sided / two-sided test
параметрический / непараметрический	parametric / nonparametric
критерий Манна-Уитни	Mann-Whitney U test
перестановочный тест	permutation test
размер эффекта	effect size
множественные сравнения	multiple comparisons (testing)
групповая вероятность ошибки I рода	family-wise error rate (FWER)
доля ложных отклонений	false discovery rate (FDR)
дисперсионный анализ	analysis of variance (ANOVA)
межгрупповая / внутригрупповая изменчивость	between- / within-group variability
попарные сравнения после ANOVA	post hoc tests
таблица сопряжённости	contingency table
критерий согласия	goodness-of-fit test

7 Регрессия

зависимая переменная (отклик)	dependent variable (response, target)
независимая переменная (предиктор)	independent variable (predictor, regressor)
метод наименьших квадратов (МНК)	ordinary least squares (OLS)
остатки	residuals
коэффициент детерминации	coefficient of determination (R^2)
мультиколлинеарность	multicollinearity
гетероскедастичность	heteroscedasticity
фиктивная переменная	dummy variable
взаимодействие признаков	interaction

шансы; отношение шансов	<i>odds; odds ratio</i>
обобщённая линейная модель	<i>generalized linear model (GLM)</i>
регуляризация (гребневая, лассо)	<i>regularization (ridge, lasso)</i>

8-9 Эксперименты и временные ряды

контрольная / тестовая группа	<i>control / treatment group</i>
рандомизация	<i>randomization</i>
минимальный обнаруживаемый эффект	<i>minimum detectable effect (MDE)</i>
снижение дисперсии	<i>variance reduction</i>
временной ряд	<i>time series</i>
тренд; сезонность	<i>trend; seasonality</i>
лаг	<i>lag</i>
автокорреляционная функция (АКФ)	<i>autocorrelation function (ACF)</i>
частная АКФ (ЧАКФ)	<i>partial autocorrelation function (PACF)</i>
белый шум	<i>white noise</i>

стационарность	<i>stationarity</i>
экспоненциальное сглаживание	<i>exponential smoothing</i>
горизонт прогноза	<i>forecast horizon</i>

A-B Причинность, байес, ML

конфаундер (вмешивающийся фактор)	<i>confounder</i>
смещение отбора	<i>selection bias</i>
средний эффект воздействия	<i>average treatment effect (ATE)</i>
разность разностей	<i>difference-in-differences (DiD)</i>
априорное / апостериорное распределение	<i>prior / posterior distribution</i>
сопряжённое априорное распределение	<i>conjugate prior</i>
кросс-валидация (скользящий контроль)	<i>cross-validation</i>
переобучение	<i>overfitting</i>
компромисс смещения и разброса	<i>bias-variance tradeoff</i>
утечка данных	<i>data leakage</i>

Частые ловушки

РУССКИЙ	ENGLISH	НА ЧТО ОБРАТИТЬ ВНИМАНИЕ
дисперсия	<i>variance</i>	<i>dispersion</i> в английском — «разброс» вообще; дисперсионный анализ = ANOVA
стандартное (среднеквадратическое) отклонение	<i>standard deviation, SD</i>	у Гмурмана — «среднее квадратическое отклонение»
стандартная ошибка	<i>standard error, SE</i>	разброс <i>оценки</i> (например, среднего), а не данных: $SE = \sigma/\sqrt{n}$
выборочная дисперсия	<i>sample variance</i>	в русских учебниках часто делят на n , а деление на $n - 1$ называют «исправленной»; в английских <i>sample variance</i> обычно уже с $n - 1$. В Python: <code>np.var</code> , <code>np.std</code> по умолчанию <code>ddof=0</code> ($\div n$), а pandas <code>.var()</code> , <code>.std()</code> — <code>ddof=1</code> ($\div (n - 1)$)
эксцесс	<i>kurtosis</i>	<code>scipy.stats.kurtosis</code> и pandas <code>.kurt()</code> по умолчанию дают <i>избыточный эксцесс</i> ($kurtosis - 3$): у нормального распределения он равен 0
квантиль	<i>quantile</i>	квантиль уровня 0,9 = 90-й перцентиль: <code>np.quantile(x, 0.9)</code> = <code>np.percentile(x, 90)</code> ; способы интерполяции у программ разные (параметр <code>method</code>)
выборка	<i>sample</i>	в ML-жаргоне <i>sample</i> часто означает одно наблюдение (строку), в статистике — весь набор наблюдений
статистика	<i>statistics / statistic</i>	наука — <i>statistics</i> ; функция от выборки (например, среднее) — <i>a statistic</i>
оценка	<i>estimate / estimator</i>	число, посчитанное по выборке / правило его расчёта (случайная величина)
правдоподобие	<i>likelihood</i>	$\neq$ <i>probability</i> : функция параметра при фиксированных данных, в сумме не обязана давать 1
выборочное распределение (распределение статистики)	<i>sampling distribution</i>	распределение оценки по многим выборкам, а не распределение самих данных
статистический критерий	<i>statistical test</i>	«критерий Стьюдента» = Student's t-test
уровень значимости α ; р-значение	<i>significance level; p-value</i>	p-value в строгих учебниках — «достигаемый уровень значимости»; это не вероятность того, что H_0 верна
статистически значимый	<i>statistically significant</i>	$\neq$ практически важный: смотрите на размер эффекта (effect size) и ДИ

РУССКИЙ	ENGLISH	НА ЧТО ОБРАТИТЬ ВНИМАНИЕ
ошибка I / II рода; мощность	type I / II error; power	ошибка I рода — ложноположительный вывод (false positive); мощность = $1 - \beta$
доверительный интервал	confidence interval	trustworthy — «надёжный», а не «доверительный»; байесовский credible interval — «байесовский (достоверный) интервал»
интервал прогноза	prediction interval	шире доверительного интервала для среднего отклика: учитывает разброс отдельного наблюдения
шансы	odds	не вероятность: odds = $p / (1 - p)$; при $p = 0,8$ шансы 4 : 1
функция распределения	cumulative distribution function, CDF	в советских учебниках $F(x) = P(X < x)$, в англоязычных — $P(X \leq x)$
стационарность в широком смысле	weak (covariance) stationarity	«в узком смысле» = strict stationarity
прогноз	forecast	forecast — прогноз будущих значений ряда; prediction — любой ответ модели

Перевод Брюса (БХВ, 2021). Встречаются нестандартные варианты: «разведывательный анализ» (принято — разведочный, EDA), «популяционное среднее» (среднее генеральной совокупности), «перекрёстный контроль» (кросс-валидация), «отношение перевесов» (отношение шансов), «переподгонка» (переобучение), «матрица путаницы» (матрица ошибок), «прецизионность» (точность, precision).

6 Источники

★ — основной комплект, ○ — дополнительно. Группы идут в порядке этапа 0 и шагов цикла.
Уровень сложности: ●○○○ вводный ●●○○ базовый ●●●○ средний ●●●● продвинутый — подробнее в разделе 1.

источник	ЗАЧЕМ И ЧТО ЧИТАТЬ	ССЫЛКА
○ 3Blue1Brown «Essence of calculus», «Essence of linear algebra» YouTube ●○○○ вводный EN видео бесплатно	Геометрическая интуиция для производных, интегралов, векторов и матриц: 12 и 16 коротких видео.	youtube.com (calculus) youtube.com (linear algebra)
○ Хендбук Яндекса «Математика для анализа данных» Яндекс Образование и ФКН ВШЭ нужно: основы высшей математики и Python (по словам авторов) ●●●○ средний RU Py задачи бесплатно	Гл. 3 — матанализ (производные, градиент), гл. 4 — линейная алгебра, гл. 6 — теория вероятностей; с задачами и кодом. Матстата нет.	education.yandex.ru/handbook/math
○ McKinney «Python for Data Analysis», 3-е изд. книга автора pandas · открытая онлайн-версия нужно: основы Python ●●○○ базовый EN Py бесплатно	NumPy, pandas, очистка данных и графики — инструменты для всех этапов плана.	wesmckinney.com/book

Интуиция и визуализация шаг 1 цикла

★ Карпов «Основы статистики», ч. 1 Stepik, Институт биоинформатики ●○○○ вводный RU видео задачи бесплатно	Одно из лучших объяснений базы на русском; более 6 тыс. отзывов. Ч. 2 (номинативные данные, непараметрика) и ч. 3 (регрессия подробнее, смешанные модели) — по желанию, уровень базовый, местами R.	stepik.org/course/76 (ч. 1) .../524 (ч. 2) .../2152 (ч. 3)
★ StatQuest Josh Starmer ●○○○ вводный EN видео бесплатно	Короткие визуальные объяснения; плейлист «Statistics Fundamentals» идёт от простого к сложному. Конкретные видео указаны в карточках этапов.	statquest.org/video_index

Интуиция и визуализация шаг 1 цикла

Seeing Theory

Brown University

●○○○ вводный EN бесплатно

Интерактивные визуализации: вероятность, ЦПТ, ДИ, бутстрэп, байес, регрессия. Сайт в архивном режиме, но работает.

seeing-theory.brown.edu

Теория с точными формулировками шаг 2 цикла

★ Лагутин «Наглядная математическая статистика»

Лаборатория знаний, 9-е и 10-е изд.

нужно: начала матанализа

●●●○ средний RU задачи решения

Теорвер и матстат через примеры и задачи с решениями. Главный учебник на русском в этом плане; его рекомендуют и курс ФКН ВШЭ, и Ульяновкин.

litres.com (электронная версия)

○ Чернова «Теория вероятностей», «Математическая статистика»

НГУ, лекции

нужно: матанализ; для матстата — теорвер

●●●○ продвинутый RU бесплатно

Короткие ёмкие лекции с доказательствами. Автор просит не выкладывать их на других сайтах — скачивайте со страницы НГУ.

tvims.nsu.ru/chernova

○ МГУ, физфак: пособия по оцениванию и проверке гипотез

кафедра математического моделирования и информатики

нужно: матанализ, теорвер

●●●○ продвинутый RU бесплатно

Справочник со строгими формулировками; есть отдельная лекция про p-value.

cmp.phys.msu.ru/ru/study/math-ms

★ OpenIntro «Introduction to Modern Statistics», 2-е изд.

Çetinkaya-Rundel, Hardin

нужно: школьная алгебра

●○○○ базовый EN задачи решения

бесплатно

Тщательные формулировки, реальные данные, бутстрэп и рандомизация; ответы к нечётным упражнениям. Код на R, но читать можно без него. «Statistically discernible» вместо «significant» — выбор авторов.

openintro-ims.netlify.app

○ Penn State STAT 414 / STAT 415

открытые конспекты

нужно: матанализ; для 415 — STAT 414

●●●○ средний EN бесплатно

414 — вероятность; 415 — оценивание, ДИ, гипотезы, непараметрика, байес. Хорошо написанные «статьи» по отдельным темам.

online.stat.psu.edu/stat414
online.stat.psu.edu/stat415

○ Harvard Stat 110

J. Blitzstein

нужно: матанализ

●●●○ средний EN видео задачи

бесплатно

Теорвер с нуля и глубоко: видеолекции, книга, листки с упражнениями. Задачи непростые.

projects.iq.harvard.edu/stat110

Python: учебники и курсы шаг 3 цикла

★ Downey «Think Stats», 3-е изд.

2025 · O'Reilly / Green Tea Press

нужно: основы Python

●○○○ базовый EN Py задачи бесплатно

Основная книга с кодом: каждая глава — ноутбук для Colab, от EDA до регрессии и временных рядов. Формальных выводов мало — формулировки сверяйте с Лагутиным или OpenIntro.

allendowney.github.io/ThinkStats

★ MatStat-AB

Ф. Ульяновкин

нужно: основы матанализа и Python

●●●○ средний RU Py видео бесплатно

Курс по неделям: описательная статистика → ЦПТ → оценки, ДИ, гипотезы, бутстрэп, А/В → регрессия, временные ряды, байес. Записи лекций — по ссылке в README.

github.com/FUlyankin/matstat-AB

○ Yet Another MatStat Course (YAMC)

Ф. Ульяновкин, ФКН ВШЭ

нужно: теорвер (этап 2)

●●●○ продвинутый RU видео задачи

Прикладной матстат и А/В университетского уровня: темы «База» — средний уровень, «Про» — продвинутый. Записи 2022–2026; материалы и ДЗ — в телеграм-канале курса.

github.com/FUlyankin/yet_another_matstat_course

Python: учебники и курсы шаг 3 цикла

★ ISLP — An Introduction to Statistical Learning with Python

James, Witten, Hastie, Tibshirani, Taylor · 2023

нужно: этапы 1–5; матрицы — на уровне обозначений

●●●○ средний EN Py задачи бесплатно

Регрессия, классификация, ресэмплинг, регуляризация, множественное тестирование; лабораторные на Python в каждой главе, бесплатный PDF, онлайн-курсы авторов.

statlearning.com

○ Брюс, Брюс, Гедек «Практическая статистика для специалистов Data Science», 2-е изд.

O'Reilly 2020 · БХВ 2021

нужно: основы Python или R

●○○○ базовый EN RU Py R

Справочник: как статистические понятия называются в DS (гл. 1–4). Упражнений нет. В переводе нестандартные термины (см. раздел 5) — лучше оригинал. 3-е изд. (2026) вышло как «AI-Assisted Statistics for Data Scientists».

oreilly.com (2-е изд.)
bhv.ru (перевод)

○ Coursera: Probability & Statistics for ML & Data Science

DeepLearning.AI, Luis Serrano

нужно: Python; школьная математика

●○○○ базовый EN Py платно*

Распределения, оценивание, проверка гипотез с лабораторными на Python; 93% слушателей довольны.

coursera.org (DeepLearning.AI)

○ Coursera: Statistics with Python

University of Michigan

нужно: школьная алгебра

●○○○ базовый EN Py платно*

Три курса начального уровня: визуализация, ДИ, гипотезы, регрессия, байесовские методы.

coursera.org (Michigan)

Задачи с решениями шаг 4 цикла

★ MIT 18.05 Introduction to Probability and Statistics

MIT OpenCourseWare, 2022

нужно: матанализ, включая кратные интегралы

●●●○ средний EN задачи решения
бесплатно

Задания с решениями и онлайн-проверкой ответов, экзамены с решениями; R нужен лишь в отдельных заданиях.

ocw.mit.edu (18.05)

○ Коршунов, Чернова «Сборник задач и упражнений по математической статистике»

Институт математики СО РАН, 2-е изд., 2004

нужно: уверенный теорвер

●●●● продвинутый RU задачи бесплатно

461 задача: оценки, ММП, ДИ, проверка гипотез — от простых к сложным.

old.math.nsc.ru (PDF)

○ Гмурман «Руководство к решению задач по теории вероятностей и математической статистике»

Юрайт, 11-е изд.

нужно: интегралы — для непрерывных величин

●○○○ базовый RU задачи решения

Тренажёр типовых задач с решениями и ответами. Обозначения старые ($F(x) = P(X < x)$, «исправленная» дисперсия), расчёты вручную — для понимания и кода берите другие источники.

ura.it.ru

○ Stepik «Теория вероятностей и математическая статистика» (курс 182381)

КФУ · рейтинг 4,8 (26 отзывов) · около 10 тыс. учащихся

нужно: основы матанализа

●○○○ базовый RU задачи бесплатно

368 тестов с автопроверкой: события, распределения, оценки, гипотезы, корреляция. Курс начального уровня для экономистов 2-го курса, без Python — тренажёр перед Stepik 326.

stepik.org/course/182381

○ Stepik «Математическая статистика» (курс 326)

рейтинг 4,7 · около 43 тыс. учащихся

нужно: матанализ и теорвер

●●●○ средний RU задачи бесплатно

187 тестов для самопроверки: описательная статистика, ДИ, гипотезы, регрессия.

stepik.org/course/326

○ Демешев «Культурный код»

сборник задач

нужно: уверенный теорвер

●●●● продвинутый RU задачи бесплатно

Красивые нетривиальные задачи по теорверу и матстату — если хочется сложнее.

github.com/bdemeshev/probability_dna

Специализации этапы 8–9 и важные темы

★ Кохави, Тан, Сюй «Доверительное A/B-тестирование» ДМК Пресс, 2021 · orig. «Trustworthy Online Controlled Experiments», 2020 нужно: этапы 4–5 ●●○○ базовый RU EN	Главная книга по онлайн-экспериментам. На сайте книги — бесплатная гл. 1 и errata. experimentguide.com
★ Hyndman, Athanasopoulos и др. «Forecasting: Principles and Practice, the Pythonic Way» OTexts, онлайн с 2025 нужно: регрессия (этап 7) ●●○○ базовый EN Py задачи бесплатно	Python-версия классического учебника fpp3: statsforecast, упражнения в конце глав, новые главы про нейросети и foundation-модели. otexts.com/fpppy
○ Нильсен «Практический анализ временных рядов» Диалектика, 2021 нужно: Python или R ●●○○ базовый RU Py R	Прикладной обзор на русском: от подготовки данных до ML и глубокого обучения для рядов. labirint.ru
★ Facure «Causal Inference for the Brave and True» онлайн-книга нужно: регрессия (этап 7) ●●●○ средний EN Py бесплатно	Причинный вывод простым языком: рандомизация, регрессия, мэтчинг, diff-in-diff, синтетический контроль. matheusfacure.github.io/python-causality-handbook
★ Downey «Think Bayes», 2-е изд. Green Tea Press нужно: основы Python, этап 2 ●●○○ базовый EN Py решения бесплатно	Байесовская статистика через вычисления; ноутбуки для Colab и решения упражнений. allendowney.github.io/ThinkBayes2
○ Дэвидсон-Пайлон «Вероятностное программирование на Python» Питер, 2019 · orig. «Bayesian Methods for Hackers» нужно: основы Python ●●○○ базовый RU EN Py	Байес на PyMC; английский оригинал бесплатно на GitHub. piter.com (перевод) github.com (оригинал)
○ Raschka «Model Evaluation, Model Selection, and Algorithm Selection in Machine Learning» arXiv, 2018 нужно: основы ML ●●●○ средний EN бесплатно	Обзор: отложенная выборка, кросс-валидация, бутстрэп, статистическое сравнение моделей. arxiv.org/abs/1811.12808

Для углубления и справки после плана

○ Wasserman «All of Statistics» Springer, 2004 нужно: матанализ, линейная алгебра, теорвер ●●●● продвинутый EN	Весь матстат сжато и строго; удобен как справочник, когда база уже есть. stat.cmu.edu/~larry/all-of-statistics
○ Casella, Berger «Statistical Inference», 2-е изд. переиздание Routledge, 2024 нужно: матанализ, теорвер уровня Stat 110 ●●●● продвинутый EN задачи	Строгая теория статистического вывода — классический университетский учебник. routledge.com
○ Hastie, Tibshirani, Friedman «The Elements of Statistical Learning» Springer нужно: линейная алгебра, ISLP ●●●● продвинутый EN бесплатно	Продвинутый statistical learning — после ISLP. hastie.su.domains/ElemStatLearn

○ CrossValidated Q&A по статистике EN бесплатно	Ответы на конкретные «почему» — ищите по названию критерия или понятия.	stats.stackexchange.com
○ Документация scipy.stats и statsmodels официальная EN Py бесплатно	Какие критерии реализованы и с какими допущениями — сверяйтесь перед использованием.	docs.scipy.org (scipy.stats) statsmodels.org

* На Coursera обычно бесплатно открыт первый модуль и есть 7-дневный пробный период; на часть программ можно подать заявку на финансовую помощь.

7 Вводное чтение

Научно-популярные книги — хороший вход в тему до этапа 1 или параллельно с ним: они дают интуицию и «статистическое мышление». Определения и формулы берите из учебников.

Шпигельхалтер «Искусство статистики. Как находить ответы в данных» МИФ, 2021 ●○○○ вводный

Лучший вход в тему: разборы реальных исследований, есть определения и формулы. mann-ivanov-ferber.ru

Уилан «Голая статистика» МИФ ●○○○ вводный

Лёгкое чтение о том, как работают ЦПТ, регрессия и опросы и как статистикой манипулируют. mann-ivanov-ferber.ru

Савельев «Статистика и котики» АСТ ●○○○ вводный

Очень короткое введение на вечер; отзывы расходятся — от «понятно и без воды» до «пустая». Удобно, чтобы объяснить азы тем, кто далёк от статистики. chitai-gorod.ru

Ключи к «Проверь себя»

- 0 $\ln L = 3 \ln p + 7 \ln(1 - p)$; производная $3/p - 7/(1 - p) = 0$ даёт $p = 0,3$ — это оценка максимального правдоподобия доли «успехов» (3 из 10). Матрица 2×3 , умноженная на вектор длины 3, даёт вектор длины 2.
- 1 Да. Например, $y = x^2$ при x , симметричном относительно нуля: зависимость полная, а $r \approx 0$ — Пирсон измеряет только линейную связь.
- 2 Из независимости следует некоррелированность, но не наоборот (тот же пример $y = x^2$). Для совместно нормальных величин понятия совпадают.
- 3 SD — разброс данных; SE — разброс оценки (например, среднего) от выборки к выборке: $SE = \sigma/\sqrt{n}$, уменьшается с ростом n .
- 4 Процедура построения даёт интервалы, которые покрывают истинный параметр в 95% выборок. Параметр не случаен: конкретный интервал его либо содержит, либо нет.
- 5 p -value — вероятность получить такие или более экстремальные данные, если H_0 верна. Это вероятность данных при H_0 , а не H_0 при данных.
- 6 Пар будет 10; если все H_0 верны, шанс хотя бы одной ложной находки при $\alpha = 0,05$ — порядка $1 - 0,95^{10} \approx 40\%$. Нужны ANOVA и поправка на множественные сравнения (Холм, Тьюки).
- 7 Коэффициент описывает связь при фиксированных остальных признаках. Без рандомизации её может создавать неучтённый конфаундер или обратная причинность.
- 8 Многократная проверка по ходу теста раздувает долю ложноположительных результатов далеко выше α . Размер выборки фиксируют заранее или используют последовательные методы.
- 9 Перемешивание пускает будущие наблюдения в обучение (утечка), а соседние точки зависимы. Валидируют «по времени»: обучение на прошлом, проверка на следующем отрезке.
- А Конфаундер влияет и на воздействие, и на результат. Парадокс Симпсона: в каждой подгруппе эффект одного знака, а в объединённых данных — другого (классический пример — приём в Беркли, 1973).
- Б Доверительный интервал — свойство процедуры (95% таких интервалов покрывают параметр). Байесовский — прямое утверждение «параметр в интервале с вероятностью 95%» при выбранном априорном распределении.
- В Бутстрэп по тестовым объектам (перевыборка с возвращением → перцентили метрики) или биномиальный интервал для доли верных ответов, например интервал Уилсона.

О ДОРОЖНОЙ КАРТЕ

Составитель — Claude (Anthropic). Дорожная карта подготовлена искусственным интеллектом: источники и ссылки проверены в сентябре 2026 года, набор тем сверен с официальными программами курсов университетов. Экспертом-человеком она не рецензировалась, поэтому неточности возможны: если найдёте ошибку или неработающую ссылку, сообщите в разделе Issues репозитория проекта на GitHub. Там же лежит справочник основных терминов к этой карте.

Лицензия CC BY 4.0: текст и схемы можно копировать, распространять и переделывать, в том числе для коммерческого использования, указав источник. Права на упомянутые книги, курсы и видео принадлежат их авторам.