

Статистика для Data Science: основные термины

87 ключевых понятий — точные определения, формулы, пояснения, примеры, код и графики: от типов данных до метрик ML

КАК УСТРОЕНА СТАТЬЯ

ЗАГоловок

термин по-русски; справа — английское название и обозначение

ОПРЕДЕЛЕНИЕ

точная формулировка в стиле учебника — главное в статье

ФОРМУЛЫ

определяющие и расчётные формулы

ПОЯСНЕНИЕ

как понимать, свойства, связь с другими понятиями

ПРИМЕНЕНИЕ

когда и для чего использовать

ПРИМЕР

короткий расчёт; все числа проверены кодом

ЛОВУШКА

частая ошибка или путаница в терминах

РУТНОН

функции для расчёта

СВЯЗИ

связанные статьи и ► видео — ссылки кликабельны

КАК ПОЛЬЗОВАТЬСЯ

Разделы идут в порядке дорожной карты: номер раздела совпадает с номером этапа, а материалы для подробного изучения собраны в карточках этапов карты.

Для первого знакомства хватит определений, пояснения и примера; формулы, ловушки и код пригодятся при решении задач и в работе. В конце — указатель русских и английских терминов со страницами.

Сокращения в коде: np — NumPy, pd — pandas, stats — scipy.stats, optimize — scipy.optimize, sm / smf — statsmodels.api/formula.api; функции sklearn и statsmodels — из их модулей (указаны в комментариях).

ОБОЗНАЧЕНИЯ					
$x_1, \dots, x_n$	наблюдения (выборка), n — объём выборки	X, Y	случайные величины		
$\bar{x}, s^2, s$	выборочные среднее, дисперсия, стандартное отклонение	μ, σ^2, σ	те же характеристики генеральной совокупности		
$p, \hat{p}$	доля (вероятность) и её оценка по выборке	$\theta, \hat{\theta}$	параметр и его оценка («шляпка» — оценка)		
$EX, \text{Var } X$	математическое ожидание и дисперсия	cov, r	ковариация, коэффициент корреляции		
$P(A), P(A B)$	вероятность, условная вероятность	$\Phi(z)$	функция распределения $N(0; 1)$		
$z_q, t_q(\nu)$	квантили уровня q распределений $N(0; 1)$ и Стьюдента	α, β	вероятности ошибок I и II рода		
H_0, H_1	нулевая и альтернативная гипотезы	$X \sim F, \overset{a}{\sim}$	X имеет распределение F ; «асимптотически (при $n \rightarrow \infty$) имеет распределение»		
н. о. р. (i.i.d.)	независимые одинаково распределённые				

1	Данные и описательная статистика	2	2	Вероятность и распределения	8	3	Выборки, ЗБЧ и ЦПТ	11
4	Оценивание	14	5	Проверка гипотез	16	6	Несколько групп и таблицы	21
7	Регрессия и оптимизация	23	8	А/В-тесты и эксперименты	28	9	Временные ряды	29
A	Причинный вывод	31	B	Байесовская статистика	33	B	Статистика в ML, метрики	34
≡	Указатель терминов	38						

О СПРАВОЧНИКЕ

Составитель — Claude (Anthropic). Справочник подготовлен искусственным интеллектом: числа в примерах пересчитаны кодом, фрагменты Python запускаются, текст дважды проверен отдельными проверочными прогонами ИИ. Экспертом-человеком он не рецензировался, поэтому неточности возможны: если найдёте ошибку, сообщите о ней [в разделе Issues репозитория проекта на GitHub](#). Актуальные версии справочника и дорожная карта к нему — на сайте xcosh.github.io/statistics-for-data-science.

Лицензия CC BY 4.0: справочник можно копировать, распространять и переделывать, в том числе для коммерческого использования, указав источник.

Как устроены данные и как коротко описать выборку: центр, разброс, форма распределения, связь признаков.

Генеральная совокупность и выборка *population, sample*

ОПРЕДЕЛЕНИЕ

Генеральная совокупность — множество всех объектов (значений признака), о которых делается вывод; в математической статистике её описывают распределением случайной величины X . Выборка объёма n — наблюдаемые значения $x_1, \dots, x_n$, которые рассматривают как реализации случайных величин $X_1, \dots, X_n$; в базовой модели эти величины независимы и распределены так же, как X (н. о. р. — независимые одинаково распределённые). Простая случайная выборка из конечной совокупности объёма N — отбор без возвращения, при котором все наборы из n объектов равновероятны; её наблюдения одинаково распределены, но зависимы, и при $n \ll N$ их приближённо считают н. о. р.

ПОЯСНЕНИЕ

Описательная статистика описывает выборку; статистический вывод по выборке оценивает свойства генеральной совокупности и указывает погрешность этой оценки. Вывод корректен, только если выборка репрезентативна: отбор случайный, без систематических перекосов. Опрос только активных пользователей даёт смещение отбора (selection bias).

ПРИМЕР

все клиенты банка — генеральная совокупность; 2 000 клиентов, случайно отобранных из полного списка, — простая случайная выборка объёма $n = 2000$.

ЛОВУШКА

в ML «sample» часто означает одно наблюдение (строку таблицы), а в статистике — весь набор из n наблюдений.

PYTHON

```
df.sample(n=2000, random_state=42) # случайная выборка без возвращения
```

СВЯЗИ

[параметр](#) · [выборочное распределение](#) · [A/B-тест](#)

Типы данных и шкалы измерения *data types, levels of measurement*

ОПРЕДЕЛЕНИЕ

Признак (переменная) — измеряемая характеристика объекта. Количественные признаки принимают числовые значения, с которыми имеют смысл арифметические операции: дискретные — отдельные значения (число заказов), непрерывные — любые значения из интервала (время, сумма). Категориальные (качественные) признаки принимают значения из конечного набора категорий: номинальные — без порядка (город), порядковые — с естественным порядком (оценка 1–5). Шкала измерения определяет, какие операции и статистики допустимы.

ШКАЛА	ПРИМЕРЫ	ДОПУСТИМЫЕ ОПЕРАЦИИ	ЦЕНТР	РАЗБРОС	СВЯЗЬ И КРИТЕРИИ
Номинальная категории без порядка	город, браузер, группа A/B, пол	$=, \neq$	мода, доли	—	χ^2 , точный критерий Фишера, V Крамера
Порядковая категории с порядком	оценка 1–5, уровень образования	+ сравнение $<, >$	медиана, мода	квантили, IQR	Спирмен, Кендалл, Манна– Уитни
Интервальная ноль условный	температура в °C, календарная дата, IQ	+ разности $x_1 - x_2$	среднее, медиана	s , IQR	t-критерии, Пирсон, регрессия
Отношений есть абсолютный ноль	доход, время, вес, число заказов	+ отношения x_1/x_2	+ геометрическое среднее	+ коэффициент вариации	то же; часто логарифмирование

Операции и статистики накапливаются сверху вниз: всё, что допустимо для номинальной шкалы, допустимо и для порядковой, и т. д. Интервальную шкалу и шкалу отношений вместе называют количественными; они бывают дискретными (число заказов) и непрерывными (время).

ПОЯСНЕНИЕ

Бинарный признак (0/1) — частный случай номинального; его среднее равно доле единиц. Числовые коды категорий (город = 1, 2, 3) не делают признак количественным: среднее кода бессмысленно. Порядковые шкалы нельзя усреднять как числа без оговорок: разница между оценками 1 и 2 не обязана равняться разнице между 4 и 5.

ПРИМЕНЕНИЕ	Тип признака определяет выбор статистик, графиков и критериев (таблица «Какой критерий выбрать») и способ кодирования в ML: one-hot для номинальных, порядковое кодирование для порядковых, масштабирование для количественных.
PYTHON	<pre>df.dtypes; df.describe(include='all') df['city'] = df['city'].astype('category') pd.Categorical(x, categories=['низкий', 'средний', 'высокий'], ordered=True)</pre>
СВЯЗИ	мода · медиана · корреляция Спирмена · критерий χ^2 · фиктивные переменные

Среднее арифметическое mean, sample mean $\bar{x}$

ОПРЕДЕЛЕНИЕ	Выборочное среднее — сумма значений, делённая на их количество. Взвешенное среднее — сумма значений с весами $w_i \geq 0$, делённая на сумму весов.
ФОРМУЛЫ	$\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i, \quad \bar{x}_w = \frac{\sum_i w_i x_i}{\sum_i w_i}$
ПОЯСНЕНИЕ	Среднее минимизирует сумму квадратов отклонений: $\sum (x_i - c)^2$ минимальна при $c = \bar{x}$; сумма отклонений $\sum (x_i - \bar{x}) = 0$. Среднее чувствительно к выбросам и длинным хвостам: изменение одного значения на Δ сдвигает $\bar{x}$ на Δ/n . Устойчивые альтернативы — медиана и усечённое среднее (отбрасывают долю наименьших и наибольших значений).
ПРИМЕР	зарплаты 40, 45, 50, 55 и 400 тыс. руб.: $\bar{x} = 590/5 = 118$ тыс., хотя четверо из пяти получают не больше 55 тыс.; медиана и усечённое на 20% среднее (без минимума и максимума) — 50 тыс.
PYTHON	<pre>np.mean(x); np.average(x, weights=w); stats.trim_mean(x, 0.2)</pre>
СВЯЗИ	медиана · матожидание · выброс

Медиана median

ОПРЕДЕЛЕНИЕ	Медиана выборки — средний элемент вариационного ряда $x_{(1)} \leq x_{(2)} \leq \dots \leq x_{(n)}$: $x_{((n+1)/2)}$ при нечётном n и полусумма $x_{(n/2)}$ и $x_{(n/2+1)}$ при чётном. Медиана распределения — число m , для которого $P(X \leq m) \geq 1/2$ и $P(X \geq m) \geq 1/2$.
ПОЯСНЕНИЕ	Медиана устойчива к выбросам: чтобы сдвинуть её сколь угодно далеко, нужно изменить половину наблюдений (у среднего достаточно одного). Минимизирует сумму модулей отклонений $\sum x_i - c $. При правой асимметрии обычно меньше среднего (рис. 5).
ПРИМЕР	для 1, 3, 4, 10 медиана $(3 + 4)/2 = 3,5$, среднее 4,5; для зарплат из статьи «Среднее» — 50 тыс.
PYTHON	<pre>np.median(x); df['x'].median()</pre>
СВЯЗИ	квантиль · ящик с усами · асимметрия · метрики регрессии

Мода mode

ОПРЕДЕЛЕНИЕ	Мода — наиболее часто встречающееся значение выборки; для дискретного распределения — значение с наибольшей вероятностью, для непрерывного — точка максимума плотности. Распределение с двумя (несколькими) локальными максимумами плотности называют бимодальным (мультимодальным).
ПОЯСНЕНИЕ	Мода — единственная мера центра для номинальных признаков. Бимодальность часто означает смесь двух групп (будни и выходные, новые и постоянные клиенты) — их стоит анализировать отдельно.
PYTHON	<pre>df['city'].mode(); df['city'].value_counts(normalize=True)</pre>
СВЯЗИ	типы данных · ящик с усами

Квантиль, перцентиль, квартиль quantile, percentile, quartiles Q_1, Q_3

ОПРЕДЕЛЕНИЕ

Квантиль уровня $p \in (0; 1)$ распределения — число x_p , для которого $P(X \leq x_p) \geq p$ и $P(X \geq x_p) \geq 1 - p$; для непрерывной строго возрастающей функции распределения $x_p = F^{-1}(p)$. Перцентиль — квантиль, уровень которого выражен в процентах: 90-й перцентиль — это $x_{0,9}$. Квартили — квантили уровней 0,25, 0,5 и 0,75: Q_1 , медиана и Q_3 . Выборочный квантиль — оценка x_p по вариационному ряду.

ПОЯСНЕНИЕ

Квантили описывают распределение без предположений о его форме и устойчивы к выбросам. В инженерных метриках используют высокие перцентили (p95, p99 времени ответа): среднее скрывает хвост медленных запросов.

ПРИМЕР

«95-й перцентиль времени ответа — 800 мс»: 95% запросов обрабатываются не дольше 800 мс.

ЛОВУШКА

на малых выборках результат зависит от правила интерполяции между элементами вариационного ряда; в NumPy оно задаётся параметром `method` (по умолчанию `'linear'`), в других программах правила другие.

PYTHON

```
np.quantile(x, [0.25, 0.5, 0.75]); np.percentile(x, 95); df['x'].quantile(0.9)
```

СВЯЗИ

[медиана](#) · [IQR](#) · [функция распределения](#)

Размах и межквартильный размах range, interquartile range (IQR)

ОПРЕДЕЛЕНИЕ

Размах — разность наибольшего и наименьшего значений: $R = x_{(n)} - x_{(1)}$. Межквартильный размах — разность третьего и первого квартилей: $IQR = Q_3 - Q_1$; в этот интервал попадает центральная половина наблюдений.

ПОЯСНЕНИЕ

Размах определяется двумя крайними значениями и растёт с объёмом выборки, поэтому как мера разброса ненадёжен. IQR устойчив к выбросам; для нормального распределения $IQR \approx 1,35 \sigma$.

PYTHON

```
np.ptp(x); stats.iqr(x)
```

СВЯЗИ

[дисперсия](#) · [выброс](#) · [ящик с усами](#)

Дисперсия и стандартное отклонение variance s^2, σ^2 ; standard deviation (SD) s, σ

ОПРЕДЕЛЕНИЕ

Дисперсия — мера разброса значений вокруг среднего: средний квадрат отклонения от среднего. Выборочная (несмещённая) дисперсия s^2 — сумма квадратов отклонений от $\bar{x}$, делённая на $n - 1$; дисперсия конечной генеральной совокупности σ^2 из N элементов — сумма квадратов отклонений от μ , делённая на N . Стандартное (среднеквадратическое) отклонение — квадратный корень из дисперсии; оно измеряется в тех же единицах, что и данные.

ФОРМУЛЫ

$$s^2 = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2, \quad s = \sqrt{s^2}, \quad \sigma^2 = \frac{1}{N} \sum_{i=1}^N (x_i - \mu)^2$$

ПОЯСНЕНИЕ

Деление на $n - 1$ (поправка Бесселя) нужно потому, что отклонения считают от $\bar{x}$, а не от неизвестного μ ; тогда $Es^2 = \sigma^2$. Свойства: $\text{Var}(X + c) = \text{Var } X$, $\text{Var}(cX) = c^2 \text{Var } X$. Как читать σ : для любого распределения $P(|X - \mu| \geq k\sigma) \leq 1/k^2$ (неравенство Чебышёва), для нормального в пределах $\mu \pm \sigma$, $\mu \pm 2\sigma$ и $\mu \pm 3\sigma$ лежит $\approx 68\%$, 95% и $99,7\%$ значений. Относительный разброс — коэффициент вариации $CV = s/\bar{x}$ (для положительных величин). Устойчивые альтернативы — IQR и медианное абсолютное отклонение $MAD = \text{med } |x_i - \text{med}(x)|$; для нормальных данных $1,4826 \cdot MAD \approx \sigma$.

ПРИМЕНЕНИЕ

Разброс важен сам по себе: при одинаковом среднем времени доставки курьер с меньшим s надёжнее ([рис. 1](#)). Дисперсия входит в стандартную ошибку, доверительные интервалы, t-критерии, расчёт размера выборки для A/B-теста и функцию потерь MSE.

ПРИМЕР

данные 2, 4, 4, 4, 5, 5, 7, 9: $\bar{x} = 5$; квадраты отклонений 9, 1, 1, 1, 0, 0, 4, 16 дают в сумме 32; $s^2 = 32/7 \approx 4,57$, $s \approx 2,14$; при делении на n : $32/8 = 4$ и 2.

ЛОВУШКА

`np.var` и `np.std` по умолчанию делят на n (`ddof=0`), а `pandas .var()` и `.std()` — на $n - 1$ (`ddof=1`). Формула $\overline{x^2} - \bar{x}^2$ математически верна, но на больших числах теряет точность.

PYTHON

```
np.var(x, ddof=1); np.std(x, ddof=1); df['x'].std()
stats.variation(x) # CV, по умолчанию ddof=0
stats.median_abs_deviation(x, scale='normal') # MAD · 1,4826
```

СВЯЗИ

[стандартная ошибка](#) · [дисперсия с. в.](#) · [z-оценка](#) · [IQR](#) · [MDE](#) · [► StatQuest](#)




Рис. 1. Одинаковое среднее — разный разброс: время доставки у двух курьеров, по 60 заказов. Среднее у обоих 40 мин, стандартное отклонение — 4,9 и 13,5 мин: на курьера А можно положиться.

Выброс *outlier*

ОПРЕДЕЛЕНИЕ

Выброс — наблюдение, заметно отличающееся от основной массы данных. Строгого определения нет; распространённые правила: значение вне интервала $[Q_1 - 1,5 \text{ IQR}; Q_3 + 1,5 \text{ IQR}]$ (правило Тьюки, «усы» ящика с усами) или $|z| > 3$, где $z = (x - \bar{x})/s$.

ПОЯСНЕНИЕ

Выброс — повод проверить данные (ошибка ввода, другая подгруппа, редкое, но реальное событие), а не удалять его автоматически. Для распределений с тяжёлыми хвостами или сильной асимметрией точки за «усами» — норма (рис. 5). Правило $|z| > 3$ само страдает от выбросов: они завышают s .

ЛОВУШКА

автоматическое удаление «выбросов» из А/В-теста или обучающей выборки меняет распределение и может исказить вывод; правило обработки фиксируйте заранее.

PYTHON

```
q1, q3 = np.percentile(x, [25, 75]); iqr = q3 - q1
is_outlier = (x < q1 - 1.5 * iqr) | (x > q3 + 1.5 * iqr)
```

СВЯЗИ

[IQR](#) · [ящик с усами](#) · [медиана](#) · [асимметрия](#)

Асимметрия и эксцесс *skewness γ_1 , kurtosis γ_2*

ОПРЕДЕЛЕНИЕ

Коэффициент асимметрии — третий центральный момент, делённый на σ^3 ; при $\gamma_1 > 0$ обычно (но не всегда) длиннее правый хвост. Коэффициент эксцесса — четвёртый центральный момент, делённый на σ^4 , минус 3; он характеризует тяжесть хвостов по сравнению с нормальным распределением, у которого $\gamma_1 = \gamma_2 = 0$.

ФОРМУЛЫ

$$\gamma_1 = \frac{E(X - \mu)^3}{\sigma^3}, \quad \gamma_2 = \frac{E(X - \mu)^4}{\sigma^4} - 3$$

ПОЯСНЕНИЕ

При правой асимметрии среднее, как правило, больше медианы; так распределены доходы, суммы покупок, длительности (рис. 5). Выборочные оценки считают по выборочным моментам; на малых выборках они неустойчивы и чувствительны к выбросам.

ЛОВУШКА

в англоязычных текстах kurtosis часто означает $E(X - \mu)^4/\sigma^4$ без вычитания 3 (у нормального — 3). scipy и pandas возвращают вариант с −3; scipy по умолчанию считает без поправки на смещение, pandas — с поправкой, поэтому на малых выборках числа различаются.

PYTHON

```
stats.skew(x); stats.kurtosis(x) # минус 3; df['x'].skew(); df['x'].kurt()
```

СВЯЗИ

[среднее](#) · [медиана](#) · [выброс](#)

Гистограмма и ящик с усами *histogram, box plot*

ОПРЕДЕЛЕНИЕ

Гистограмма — столбчатая диаграмма: область значений разбита на интервалы (бины), высота столбца пропорциональна числу или доле наблюдений в интервале; нормированная на площадь 1, она оценивает плотность. Ящик с усами (диаграмма размаха) изображает Q_1 , медиану, Q_3 (ящик) и концы «усов» — самые крайние наблюдения в пределах $1,5 \text{ IQR}$ от ящика; точки за усами рисуют отдельно как выбросы (рис. 2).

ПОЯСНЕНИЕ

Вид гистограммы зависит от ширины бинов: слишком широкие скрывают форму, узкие дают шум — попробуйте несколько вариантов (правила Стёрджеса, Фридмана–Диакониса). Ящики удобны для сравнения многих групп, но скрывают форму: бимодальные данные дают «обычный» ящик (рис. 5).

PYTHON

```
plt.hist(x, bins='fd'); sns.histplot(x, stat='density')
sns.boxplot(data=df, x='group', y='value')
```

СВЯЗИ

[квантиль](#) · [IQR](#) · [выброс](#) · [мода](#) · [StatQuest: гистограммы](#) · [ящики](#)




Рис. 2. Как читать ящик с усами. Ящик — от Q_1 до Q_3 , линия — медиана, усы — до крайних наблюдений в пределах $1,5 \text{ IQR}$ от ящика, дальше — выбросы. Сверху — гистограмма тех же 120 значений.

Ковариация *covariance* $\text{cov}(X, Y)$, s_{xy}

ОПРЕДЕЛЕНИЕ

Ковариация случайных величин — математическое ожидание произведения их отклонений от своих средних; выборочная ковариация — её аналог по выборке пар (x_i, y_i) .

ФОРМУЛЫ

$$\text{cov}(X, Y) = E[(X - EX)(Y - EY)], \quad s_{xy} = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})$$

ПОЯСНЕНИЕ

Знак указывает направление линейной связи; $\text{cov}(X, X) = \text{Var } X$. Величина зависит от единиц измерения, поэтому силу связи по ней не сравнить — для этого есть корреляция. Для набора признаков считают ковариационную матрицу с элементами $\text{cov}(X_j, X_k)$; она симметрична и неотрицательно определена (используется в PCA и многомерном нормальном распределении).

PYTHON

```
np.cov(x, y) # матрица 2x2, ddof=1; df.cov()
```

СВЯЗИ

[корреляция](#) · [дисперсия с. в.](#) · [тепловая карта](#) · [StatQuest](#)

Коэффициент корреляции Пирсона *Pearson correlation coefficient* r

ОПРЕДЕЛЕНИЕ

Коэффициент корреляции — ковариация, нормированная на произведение стандартных отклонений; измеряет силу и направление линейной связи. $-1 \leq r \leq 1$. Если $s_x = 0$ или $s_y = 0$, r не определён; иначе $|r| = 1$ тогда и только тогда, когда $y_i = a + bx_i$ для всех i при некоторых a и $b \neq 0$.

ФОРМУЛЫ

$$r = \frac{s_{xy}}{s_x s_y} = \frac{\sum (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum (x_i - \bar{x})^2 \sum (y_i - \bar{y})^2}}, \quad t = \frac{r\sqrt{n-2}}{\sqrt{1-r^2}}$$

ПОЯСНЕНИЕ

Статистика t при $H_0: \rho = 0$ (для совместно нормальных данных) имеет распределение Стьюдента с $n-2$ степенями свободы — так проверяют значимость корреляции. $r \approx 0$ не означает отсутствия зависимости: при $y = x^2$ на симметричном интервале $r \approx 0$; один выброс может создать сильную корреляцию (рис. 3). r^2 — доля дисперсии y , объяснённая линейной регрессией на x .

ЛОВУШКА корреляция не доказывает причинную связь: оба признака могут зависеть от третьего (конфаундера).

PYTHON `df.corr(); stats.pearsonr(x, y) # r и p-value`

СВЯЗИ [корреляция Спирмена](#) · [ковариация](#) · [R²](#) · [тепловая карта](#) · [конфаундер](#) · [StatQuest](#)




Рис. 3. Коэффициенты Пирсона r и Спирмена r_s на примерах по 60 точек. Парабола: сильная нелинейная связь, но $r \approx 0$. Один выброс создаёт $r = 0,54$ в облаке без связи, а ранговая корреляция остаётся около нуля.

Ранговые корреляции Спирмена и Кендалла *Spearman's r_s , Kendall's τ*

ОПРЕДЕЛЕНИЕ Коэффициент Спирмена — коэффициент Пирсона, вычисленный по рангам наблюдений; измеряет силу монотонной (не обязательно линейной) связи. Коэффициент Кендалла τ — разность долей согласованных и несогласованных пар наблюдений (пара согласована, если x и y у неё упорядочены одинаково).

ФОРМУЛЫ
$$r_s = 1 - \frac{6 \sum_i d_i^2}{n(n^2 - 1)}, \quad d_i = \text{rank}(x_i) - \text{rank}(y_i); \quad \tau = \frac{C - D}{n(n - 1)/2}$$

ПОЯСНЕНИЕ C и D — числа согласованных и несогласованных пар среди всех $n(n - 1)/2$ пар наблюдений. Обе формулы верны при отсутствии совпадающих значений; при совпадениях r_s считают как коэффициент Пирсона по средним рангам, а для τ вводят поправку (`kendalltau` возвращает вариант τ_b). Коэффициенты подходят для порядковых признаков и устойчивы к выбросам (рис. 3, правая панель); $|r_s| = 1$ при строгой монотонной связи.

ПРИМЕР $y = e^x$: связь строго монотонная, но нелинейная — $r_s = 1$, а $r < 1$.

PYTHON `df.corr(method='spearman'); stats.spearmanr(x, y); stats.kendalltau(x, y)`

СВЯЗИ [корреляция](#) · [типы данных](#) · [Манна-Уитни](#)

Тепловая карта и корреляционная матрица *heatmap, correlation matrix*

ОПРЕДЕЛЕНИЕ Тепловая карта — изображение матрицы (таблицы) чисел, в котором значение каждой ячейки кодируется цветом по заданной шкале. Корреляционная матрица — квадратная матрица попарных коэффициентов корреляции признаков $R = (r_{jk})$; она симметрична, на диагонали стоят единицы.

ПОЯСНЕНИЕ Для величин со знаком (корреляции, изменения) нужна расходящаяся шкала с нейтральным цветом в нуле и симметричными относительно нуля границами (для корреляций — $[-1; 1]$); для неотрицательных величин (частоты, конверсия) — последовательная шкала одного тона от светлого к тёмному (рис. 4). У симметричной матрицы достаточно одного треугольника. Подписывайте значения в ячейках и упорядочивайте строки осмысленно (по смыслу или кластеризацией).

ПРИМЕНЕНИЕ Первичный анализ связей признаков и поиск мультиколлинеарности перед регрессией; сводные таблицы по двум измерениям (конверсия по дням недели и часам, когорты удержания); матрица ошибок классификатора; карта пропусков в данных.

ЛОВУШКА шкала, растянутая по данным, делает различие 0,02 визуально огромным; радужные палитры искажают восприятие. `df.corr()` по умолчанию считает корреляцию Пирсона — только линейную связь; при десятках признаков часть высоких корреляций окажется случайной.

PYTHON `corr = df.corr(numeric_only=True); mask = np.triu(np.ones_like(corr, dtype=bool))
sns.heatmap(corr, mask=mask, annot=True, fmt='.2f', cmap='RdBu_r', vmin=-1, vmax=1, center=0)
pivot = df.pivot_table(values='conv', index='day', columns='hour', aggfunc='mean')`

СВЯЗИ [корреляция](#) · [остатки](#) · [метрики классификации](#)




Рис. 4. Две тепловые карты (данные смоделированы). Слева — корреляционная матрица признаков квартир, нижний треугольник, расходящаяся шкала от -1 до 1: площадь, число комнат и цена связаны сильно, этаж — почти ни с чем. Справа — сводная таблица конверсии по дням недели и часам, последовательная шкала: пик — вечером в выходные.

2 Вероятность и распределения

этап 2 дорожной карты

Язык, на котором описывают случайность: события и их вероятности, случайные величины и их распределения.

Вероятность *probability, sample space Ω , event*

ОПРЕДЕЛЕНИЕ

Пространство элементарных исходов Ω — множество всех возможных исходов случайного эксперимента; событие — подмножество $A \subseteq \Omega$ из σ -алгебры событий $\mathcal{F}$ (при конечном или счётном Ω обычно берут все подмножества). Вероятность — функция P на событиях, удовлетворяющая аксиомам Колмогорова: $P(A) \geq 0$; $P(\Omega) = 1$; для попарно несовместных событий $P(A_1 \cup A_2 \cup \dots) = P(A_1) + P(A_2) + \dots$.

ФОРМУЛЫ

$$P(\bar{A}) = 1 - P(A), \quad P(A \cup B) = P(A) + P(B) - P(A \cap B)$$

ПОЯСНЕНИЕ

Классическое определение: если все исходы равновозможны, $P(A) = |A|/|\Omega|$ — доля благоприятных исходов. Частотная интерпретация: $P(A)$ — предел доли появлений A при многократном повторении эксперимента (закон больших чисел).

ПРИМЕР

бросок двух костей: $|\Omega| = 36$, сумма 7 выпадает в 6 исходах, $P = 6/36 = 1/6$.

СВЯЗИ

[условная вероятность](#) · [случайная величина](#) · 3БЧ · [► Seeing Theory](#)

Условная вероятность и формула полной вероятности *conditional probability $P(A | B)$, law of total probability*

ОПРЕДЕЛЕНИЕ

Условная вероятность события A при условии B ($P(B) > 0$) — отношение вероятности их совместного наступления к вероятности B . Формула полной вероятности: если события $H_1, \dots, H_k$ образуют разбиение Ω (попарно несовместны, в объединении дают Ω , $P(H_i) > 0$), то вероятность A равна сумме вероятностей $P(A \cap H_i) = P(A | H_i) P(H_i)$ по всем частям разбиения.

ФОРМУЛЫ

$$P(A | B) = \frac{P(A \cap B)}{P(B)}, \quad P(A) = \sum_{i=1}^k P(A | H_i) P(H_i)$$

ЛОВУШКА

$P(A | B) \neq P(B | A)$: вероятность положительного теста у больного (чувствительность) и вероятность болезни при положительном тесте — разные величины (см. формулу Байеса).

СВЯЗИ

[формула Байеса](#) · [независимость](#) · [► StatQuest](#)

Независимость *independence*

ОПРЕДЕЛЕНИЕ	События A и B независимы, если $P(A \cap B) = P(A) P(B)$ (при $P(B) > 0$ это равносильно $P(A B) = P(A)$). Случайные величины X и Y независимы, если $P(X \leq x, Y \leq y) = P(X \leq x) P(Y \leq y)$ для всех x и y .
ПОЯСНЕНИЕ	Из независимости следует некоррелированность ($\text{cov}(X, Y) = 0$, если дисперсии конечны), обратное неверно: при $X \sim U(-1; 1)$ и $Y = X^2$ ковариация равна 0, но Y полностью определяется X . Для совместно нормальных величин понятия совпадают.
ПРИМЕНЕНИЕ	Большинство статистических методов требует независимых наблюдений. Повторные измерения одного пользователя, соседние точки временного ряда, пациенты одной клиники — зависимые наблюдения; для них нужны свои методы: парные критерии, модели временных рядов, кластеризованные ошибки.
СВЯЗИ	ковариация · корреляция · метрики-отношения · автокорреляция

Формула Байеса *Bayes' theorem*

ОПРЕДЕЛЕНИЕ	Формула пересчёта вероятностей гипотез после наблюдения события A . Если $H_1, \dots, H_k$ образуют разбиение Ω , $P(H_i) > 0$ и $P(A) > 0$, то апостериорная вероятность $P(H_i A)$ пропорциональна произведению априорной вероятности $P(H_i)$ на правдоподобие $P(A H_i)$; знаменатель формулы — полная вероятность $P(A)$.
ФОРМУЛА	$P(H_i A) = \frac{P(A H_i) P(H_i)}{\sum_j P(A H_j) P(H_j)}$
ПОЯСНЕНИЕ	При редком событии даже точный тест даёт в основном ложные тревоги: результат определяет исходная (априорная) вероятность. Та же формула лежит в основе байесовской статистики и наивного байесовского классификатора.
ПРИМЕР	распространённость болезни 1%, тест находит 99% больных и ошибочно срабатывает у 5% здоровых. $P(+)=0,99 \cdot 0,01 + 0,05 \cdot 0,99 = 0,0594$, $P(\text{болен} +) = 0,0099/0,0594 \approx 0,17$.
СВЯЗИ	условная вероятность · апостериорное распределение · ▶ StatQuest

Случайная величина *random variable*

ОПРЕДЕЛЕНИЕ	Случайная величина — функция $X: \Omega \rightarrow \mathbb{R}$, сопоставляющая каждому элементарному исходу число (так, что определены вероятности $P(X \leq x)$). Дискретная принимает конечное или счётное множество значений; непрерывная (абсолютно непрерывная) имеет плотность распределения.
ПРИМЕР	число покупок за день — дискретная величина; время между заказами — непрерывная.
СВЯЗИ	функция распределения · матожидание

Функция распределения, плотность, ряд распределения *CDF $F(x)$, PDF $f(x)$, PMF*

ОПРЕДЕЛЕНИЕ	Функция распределения $F(x) = P(X \leq x)$ — неубывающая, непрерывная справа, $F(-\infty) = 0$, $F(+\infty) = 1$. Дискретную величину задают рядом распределения $p_k = P(X = x_k)$, $\sum_k p_k = 1$ (PMF). Непрерывную — плотностью $f(x) \geq 0$, для которой $F(x) = \int_{-\infty}^x f(t) dt$ и $\int_{-\infty}^{+\infty} f(x) dx = 1$.
ФОРМУЛА	$P(a < X \leq b) = F(b) - F(a) = \int_a^b f(x) dx$
ЛОВУШКА	значение плотности — не вероятность: оно может быть больше 1, а для непрерывной величины $P(X = x) = 0$. В советских учебниках $F(x) = P(X < x)$ — для непрерывных величин разницы нет, для дискретных есть.
PYTHON	<pre>stats.norm.pdf(x); stats.norm.cdf(x); stats.norm.ppf(q) # ppf — квантиль, обратная к cdf stats.binom.pmf(k, n, p)</pre>
СВЯЗИ	квантиль · случайная величина · ▶ Seeing Theory

ОПРЕДЕЛЕНИЕ

Математическое ожидание — среднее значение случайной величины, взвешенное по вероятностям (определено, если ряд или интеграл сходится абсолютно).

ФОРМУЛЫ

$$EX = \sum_k x_k p_k \text{ (дискретная)}, \quad EX = \int_{-\infty}^{+\infty} x f(x) dx \text{ (непрерывная)}$$

ПОЯСНЕНИЕ

Линейность $E(aX + bY + c) = aEX + bEY + c$ верна всегда, даже для зависимых величин. Для независимых $E(XY) = EX \cdot EY$. Выборочное среднее — оценка EX ; по закону больших чисел оно сходится к EX .

ПРИМЕР

игральная кость: $EX = (1 + 2 + \dots + 6)/6 = 3,5$ — значение, которое никогда не выпадает.

ЛОВУШКА

матожидание существует не всегда: у распределения Коши (распределения Стьюдента с одной степенью свободы) выборочное среднее не сходится ни к какому числу.

СВЯЗИ

[среднее](#) · [ЗБЧ](#) · [дисперсия с. в.](#) · [► StatQuest](#)

Дисперсия, ковариация и корреляция случайных величин $\text{Var } X$, $\text{cov}(X, Y)$, $\text{corr}(X, Y)$

ОПРЕДЕЛЕНИЕ

Дисперсия случайной величины — математическое ожидание квадрата её отклонения от математического ожидания; стандартное отклонение $\sigma = \sqrt{\text{Var } X}$. Коэффициент корреляции случайных величин — их ковариация, делённая на произведение стандартных отклонений.

ФОРМУЛЫ

$$\text{Var } X = E(X - EX)^2 = EX^2 - (EX)^2, \quad \text{corr}(X, Y) = \frac{\text{cov}(X, Y)}{\sigma_X \sigma_Y}$$

$$\text{Var}(aX + b) = a^2 \text{Var } X, \quad \text{Var}(X + Y) = \text{Var } X + \text{Var } Y + 2 \text{cov}(X, Y)$$

ПОЯСНЕНИЕ

Для некоррелированных (в частности, независимых) величин дисперсия суммы равна сумме дисперсий. Отсюда дисперсия среднего n независимых наблюдений с дисперсией σ^2 : $\text{Var } \bar{X} = \sigma^2/n$ — основа стандартной ошибки.

ПРИМЕР

игральная кость: $EX^2 = 91/6$, $\text{Var } X = 91/6 - 3,5^2 = 35/12 \approx 2,92$.

СВЯЗИ

[дисперсия](#) · [стандартная ошибка](#) · [ковариация](#)




Рис. 5. Основные распределения: плотность (для дискретных — вероятности значений), медиана и среднее, под ними — ящик с усами. При правой асимметрии среднее больше медианы; у распределений с тяжёлыми хвостами много точек за усами; у бимодального распределения ящик выглядит «обычно» и скрывает два пика; у Пуассона точек за усами много из-за дискретности: $\text{IQR} = 1$.

Основные распределения

вероятность значения (дискретные) или плотность (непрерывные), математическое ожидание, дисперсия; форма, медиана и ящик с усами — на [рис. 5](#)

РАСПРЕДЕЛЕНИЕ	$P(X = k)$ или $f(x)$	EX	$\text{Var } X$	ЧТО ОПИСЫВАЕТ	SCIPY.STATS
Бернулли $\text{Bern}(p)$	$P(1) = p, P(0) = 1 - p$	p	$p(1 - p)$	один исход «успех / неудача»: клик, покупка	<code>bernoulli(p)</code>
Биномиальное $B(n; p)$	$\binom{n}{k} p^k (1 - p)^{n-k}, k = 0, \dots, n$	np	$np(1 - p)$	число успехов в n независимых испытаниях	<code>binom(n, p)</code>
Пуассона $\text{Pois}(\lambda)$	$\frac{\lambda^k e^{-\lambda}}{k!}, k = 0, 1, \dots$	λ	λ	число редких независимых событий за интервал: заказы в минуту	<code>poisson(\lambda)</code>
Равномерное $U(a; b)$	$\frac{1}{b - a}, a \leq x \leq b$	$\frac{a + b}{2}$	$\frac{(b - a)^2}{12}$	плотность постоянна на $[a; b]$: попадание в подынтервалы равной длины равновероятно	<code>uniform(a, b - a)</code>
Нормальное $N(\mu; \sigma^2)$	$\frac{1}{\sigma\sqrt{2\pi}} e^{-(x-\mu)^2/(2\sigma^2)}$	μ	σ^2	сумма многих малых независимых эффектов; средние по ЦПТ	<code>norm(\mu, \sigma)</code>
Экспоненциальное $\text{Exp}(\lambda)$	$\lambda e^{-\lambda x}, x \geq 0$	$\frac{1}{\lambda}$	$\frac{1}{\lambda^2}$	время ожидания события при постоянной интенсивности; медиана $\ln 2 / \lambda$	<code>expon(scale=1/\lambda)</code>
Логнормальное $\ln X \sim N(\mu; \sigma^2)$	$\frac{1}{x\sigma\sqrt{2\pi}} e^{-(\ln x - \mu)^2/(2\sigma^2)}, x > 0$	$e^{\mu + \sigma^2/2}$	$(e^{\sigma^2} - 1) e^{2\mu + \sigma^2}$	положительные скошенные величины: доходы, цены; медиана e^μ	<code>lognorm(\sigma, scale=e^\mu)</code>
Стьюдента $t(\nu)$	$\frac{\Gamma(\frac{\nu+1}{2})}{\sqrt{\nu\pi}\Gamma(\frac{\nu}{2})} \left(1 + \frac{x^2}{\nu}\right)^{-(\nu+1)/2}$	0 при $\nu > 1$	$\frac{\nu}{\nu - 2}$ при $\nu > 2$	статистики t-критериев; тяжёлые хвосты	<code>t(\nu)</code>
Хи-квадрат $\chi^2(k)$	$\frac{x^{k/2-1} e^{-x/2}}{2^{k/2}\Gamma(k/2)}, x > 0$	k	$2k$	сумма квадратов k независимых $N(0; 1)$; критерии для таблиц	<code>chi2(k)</code>

Γ — гамма-функция: $\Gamma(m) = (m - 1)!$ для натуральных m . В `scipy.stats` параметры задают через `loc` и `scale`: у нормального `scale` — это σ , а не σ^2 ; у экспоненциального `scale` = $1/\lambda$; у логнормального первый параметр — σ , а `scale` = e^μ .

3

Выборки, ЗБЧ и ЦПТ

этап 3 дорожной карты

Почему по выборке можно судить о генеральной совокупности и насколько точно.

Параметр и статистика $parameter \theta, statistic T(X_1, \dots, X_n)$

ОПРЕДЕЛЕНИЕ	Параметр — числовая характеристика распределения генеральной совокупности (μ, σ^2 , доля p), обычно неизвестная. Статистика — любая функция выборки $T(X_1, \dots, X_n)$, не зависящая от неизвестных параметров ($\bar{X}, s^2$, медиана, $\max_i X_i$). Статистика — случайная величина: на другой выборке её значение будет другим.
ПОЯСНЕНИЕ	Принятые обозначения: греческие буквы — параметры совокупности, латинские буквы и «шляпки» — выборочные величины ($\hat{p}$ — оценка p).
СВЯЗИ	оценка · выборочное распределение · выборка

Закон больших чисел law of large numbers (LLN)

ОПРЕДЕЛЕНИЕ

Если $X_1, X_2, \dots$ — независимые одинаково распределённые случайные величины с конечным математическим ожиданием μ , то их выборочное среднее $\bar{X}_n$ сходится к μ при $n \rightarrow \infty$: по вероятности (закон больших чисел Хинчина) и почти наверное (усиленный закон Колмогорова).

ФОРМУЛЫ

$$P(|\bar{X}_n - \mu| > \varepsilon) \xrightarrow{n \rightarrow \infty} 0 \quad \text{для любого } \varepsilon > 0$$

ПОЯСНЕНИЕ

Обосновывает оценку вероятностей частотами, а параметров — выборочными средними. Типичное отклонение $\bar{X}_n$ от μ имеет порядок $\sigma/\sqrt{n}$ (рис. 6).

ЛОВУШКА

ЗБЧ не «компенсирует» прошлые отклонения: после пяти орлов подряд вероятность решки по-прежнему 0,5 (ошибка игрока). Отклонения не исправляются, а растворяются в большом n .

СВЯЗИ

[матожидание](#) · [ЦПТ](#) · [стандартная ошибка](#)




Рис. 6. Закон больших чисел: доля орлов в трёх сериях по 1 000 бросков монеты. Серая полоса — $0,5 \pm 1,96$ стандартной ошибки; она сужается как $1/\sqrt{n}$.

Центральная предельная теорема central limit theorem (CLT)

ОПРЕДЕЛЕНИЕ

Если $X_1, \dots, X_n$ — независимые одинаково распределённые величины с $EX_i = \mu$ и $0 < \text{Var } X_i = \sigma^2 < \infty$, то стандартизованное выборочное среднее сходится по распределению к стандартному нормальному закону.

ФОРМУЛЫ

$$\frac{\bar{X}_n - \mu}{\sigma/\sqrt{n}} \xrightarrow{d} N(0; 1), \quad \text{т. е.} \quad P\left(\frac{\bar{X}_n - \mu}{\sigma/\sqrt{n}} \leq z\right) \rightarrow \Phi(z) \quad \text{для всех } z$$

ПОЯСНЕНИЕ

На практике: при большом n среднее $\bar{X} \approx N(\mu; \sigma^2/n)$, а сумма $\approx N(n\mu; n\sigma^2)$, даже если сами данные не нормальны (рис. 7). Чем сильнее асимметрия и тяжелее хвосты, тем больше нужно n ; « $n \geq 30$ » — лишь грубый ориентир. На ЦПТ опираются z- и t-критерии, доверительные интервалы для средних и долей, анализ A/B-тестов.

СВЯЗИ

[выборочное распределение](#) · [стандартная ошибка](#) · [доверительный интервал](#) · [t-критерий](#) · [StatQuest](#)




Рис. 7. ЦПТ: распределение средних выборок объема n из скошенного экспоненциального распределения $\text{Exp}(1)$. Уже при $n = 30$ оно близко к нормальному $N(1; 1/n)$.

Выборочное распределение sampling distribution

ОПРЕДЕЛЕНИЕ

Выборочное распределение статистики T — распределение случайной величины $T(X_1, \dots, X_n)$, то есть распределение значений статистики по всем возможным выборкам объема n из генеральной совокупности.

ПОЯСНЕНИЕ

Это распределение не данных, а оценки. Из него получают стандартную ошибку, доверительные интервалы и p-value. Находят его теоретически (для нормальной выборки $\bar{X} \sim N(\mu; \sigma^2/n)$), асимптотически (по ЦПТ) или численно — бутстрэпом.

СВЯЗИ

[стандартная ошибка](#) · [ЦПТ](#) · [бутстрэп](#) · χ^2 , t и F

Стандартная ошибка standard error (SE)

ОПРЕДЕЛЕНИЕ	Стандартная ошибка оценки $\hat{\theta}$ — стандартное отклонение её выборочного распределения: $SE(\hat{\theta}) = \sqrt{\text{Var } \hat{\theta}}$. На практике используют её оценку по выборке.
ФОРМУЛЫ	$SE(\bar{x}) = \frac{\sigma}{\sqrt{n}} \approx \frac{s}{\sqrt{n}}, \quad SE(\hat{p}) = \sqrt{\frac{p(1-p)}{n}} \approx \sqrt{\frac{\hat{p}(1-\hat{p})}{n}}$ $SE(\bar{x}_1 - \bar{x}_2) = \sqrt{\frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2}} \approx \sqrt{\frac{s_1^2}{n_1} + \frac{s_2^2}{n_2}} \quad (\text{независимые выборки})$
ПОЯСНЕНИЕ	Стандартное отклонение описывает разброс данных и с ростом n не уменьшается; стандартная ошибка описывает точность оценки и убывает как $1/\sqrt{n}$: чтобы вдвое сузить интервал, нужно вчетверо больше данных.
ПРИМЕР	$s = 20, n = 100: SE(\bar{x}) = 20/\sqrt{100} = 2.$
PYTHON	<code>stats.sem(x) # s / sqrt(n), ddof=1</code>
СВЯЗИ	дисперсия · доверительный интервал · выборочное распределение · MDE · ► StatQuest

Стандартизация, z-оценка standardization, z-score

ОПРЕДЕЛЕНИЕ	Стандартизация — линейное преобразование, приводящее величину к нулевому среднему и единичному стандартному отклонению; z-оценка показывает, на сколько стандартных отклонений значение отличается от среднего.
ФОРМУЛЫ	$z = \frac{x - \mu}{\sigma}; \quad z_i = \frac{x_i - \bar{x}}{s} \quad (\text{по выборке}); \quad X \sim N(\mu; \sigma^2) \Rightarrow \frac{X - \mu}{\sigma} \sim N(0; 1)$
ПРИМЕНЕНИЕ	Сравнение величин в разных единицах; поиск выбросов ($ z > 3$); масштабирование признаков для методов, чувствительных к масштабу: регуляризованная регрессия, градиентный спуск, kNN, PCA, SVM.
ПРИМЕР	IQ = 130 при $\mu = 100, \sigma = 15: z = 2; \Phi(2) \approx 0,977$ — результат выше, чем у $\approx 97,7\%$ людей (если IQ распределён нормально).
PYTHON	<code>stats.zscore(x, ddof=1); StandardScaler().fit_transform(X) # sklearn делит на σ с ddof=0</code>
СВЯЗИ	дисперсия · градиентный спуск · регуляризация

Распределения χ^2 , Стюдента и Фишера chi-squared $\chi^2(k)$, Student's $t(k)$, Fisher's $F(k_1, k_2)$

ОПРЕДЕЛЕНИЕ	Пусть $Z, Z_1, \dots, Z_k$ — независимые $N(0; 1)$. Распределение хи-квадрат с k степенями свободы — распределение суммы $Z_1^2 + \dots + Z_k^2$. Распределение Стюдента $t(k)$ — распределение отношения $Z/\sqrt{V/k}$, где $V \sim \chi^2(k)$ не зависит от Z . Распределение Фишера $F(k_1, k_2)$ — распределение $(V_1/k_1)/(V_2/k_2)$ для независимых $V_1 \sim \chi^2(k_1)$ и $V_2 \sim \chi^2(k_2)$.
ФОРМУЛЫ	$\frac{(n-1)s^2}{\sigma^2} \sim \chi^2(n-1), \quad \frac{\bar{X} - \mu}{s/\sqrt{n}} \sim t(n-1) \quad (\text{выборка из } N(\mu; \sigma^2))$
ПОЯСНЕНИЕ	$t(k)$ симметрично, но с более тяжёлыми хвостами, чем $N(0; 1)$, и приближается к нему при $k \rightarrow \infty$: $t_{0,975}(9) \approx 2,26, t_{0,975}(99) \approx 1,98, z_{0,975} \approx 1,96$. Где встречаются: χ^2 — дисперсия нормальной выборки, критерии для таблиц сопряжённости; t — средние при неизвестной σ , коэффициенты регрессии; F — ANOVA, сравнение дисперсий, значимость регрессии в целом.
PYTHON	<code>stats.t.ppf(0.975, df=19); stats.chi2.sf(x, df=k); stats.f.sf(F, dfn, dfd)</code>
СВЯЗИ	степени свободы · t-критерий · критерий χ^2 · ANOVA

Число степеней свободы *degrees of freedom (df, ν)*

ОПРЕДЕЛЕНИЕ	Параметр распределений χ^2 , t и F ; в статистике — число независимых величин, участвующих в расчёте, за вычетом числа оценённых по ним параметров (наложенных связей).
ПРИМЕР	в s^2 входят n отклонений $x_i - \bar{x}$, но их сумма равна нулю — свободных только $n - 1$. В регрессии с p признаками и свободным членом у остатков $n - p - 1$ степеней свободы; в таблице сопряжённости $r \times c$ у критерия χ^2 их $(r - 1)(c - 1)$.
СВЯЗИ	χ^2 , t и F · дисперсия

4

Оценивание

этап 4 дорожной карты

Как по выборке получить значение параметра и показать, насколько ему можно доверять.

Точечная оценка *estimator, estimate $\hat{\theta}$*

ОПРЕДЕЛЕНИЕ	Оценка параметра θ — статистика $\hat{\theta} = \hat{\theta}(X_1, \dots, X_n)$, значение которой принимают за приближённое значение θ . Различают оценку как правило (estimator — случайная величина) и её значение на конкретной выборке (estimate — число).
ПРИМЕР	$\hat{p} = k/n$ — оценка вероятности конверсии по k покупкам из n визитов; $\bar{x}$ — оценка μ ; s^2 — оценка σ^2 .
СВЯЗИ	свойства оценок · ММП · метод моментов · параметр

Свойства оценок *bias, unbiasedness, consistency, efficiency, MSE*

ОПРЕДЕЛЕНИЕ	Смещение оценки $b(\theta) = E_{\theta}\hat{\theta} - \theta$; оценка несмещённая, если $b(\theta) = 0$ при всех θ . Состоятельная — если при любом значении θ оценка $\hat{\theta}_n$ сходится к θ по вероятности при $n \rightarrow \infty$. Эффективная — несмещённая оценка, дисперсия которой при всех θ не больше, чем у любой другой несмещённой оценки рассматриваемого класса. Качество оценки в целом измеряют среднеквадратичной ошибкой (MSE).
ФОРМУЛА	$MSE(\hat{\theta}) = E(\hat{\theta} - \theta)^2 = \text{Var } \hat{\theta} + b^2(\theta)$
ПОЯСНЕНИЕ	Несмещённость не обязательна: небольшое смещение может окупиться заметным снижением дисперсии и MSE — на этом основаны регуляризация и сжимающие оценки.
ПРИМЕР	$\bar{X}$ — несмещённая и состоятельная оценка μ ; s^2 (деление на $n - 1$) несмещённая, а $\frac{1}{n} \sum (x_i - \bar{x})^2$ смещена вниз на σ^2/n , но состоятельна.
СВЯЗИ	оценка · дисперсия · смещение и разброс · регуляризация

Функция правдоподобия *likelihood $L(\theta)$, log-likelihood $\ell(\theta)$*

ОПРЕДЕЛЕНИЕ	Функция правдоподобия — совместная вероятность (для дискретных данных) или совместная плотность (для непрерывных) наблюдаемой выборки, рассматриваемая как функция параметра θ при фиксированных данных. Для простой выборки она равна произведению вероятностей (плотностей) отдельных наблюдений.
ФОРМУЛЫ	$L(\theta) = \prod_{i=1}^n f(x_i; \theta), \quad \ell(\theta) = \ln L(\theta) = \sum_{i=1}^n \ln f(x_i; \theta)$
ЛОВУШКА	правдоподобие — не вероятность параметра: как функция θ оно не обязано интегрироваться в 1. Вероятностное распределение параметра появляется только в байесовском подходе.
СВЯЗИ	ММП · апостериорное распределение

Метод максимального правдоподобия maximum likelihood estimation (MLE)

ОПРЕДЕЛЕНИЕ

Оценка максимального правдоподобия (ОМП) — значение параметра, при котором функция правдоподобия наблюдаемой выборки максимальна: $\hat{\theta} = \arg \max_{\theta} L(\theta) = \arg \max_{\theta} \ell(\theta)$. Обычно её находят из уравнения правдоподобия $\partial \ell / \partial \theta = 0$ или численной оптимизацией.

ФОРМУЛЫ

Бернулли: $\hat{p} = \bar{x}$; Пуассон: $\hat{\lambda} = \bar{x}$; экспоненциальное: $\hat{\lambda} = 1/\bar{x}$; $N(\mu; \sigma^2)$: $\hat{\mu} = \bar{x}$, $\hat{\sigma}^2 = \frac{1}{n} \sum (x_i - \bar{x})^2$

ПОЯСНЕНИЕ

При широких условиях регулярности ОМП состоятельны, асимптотически нормальны и асимптотически эффективны. Связь с ML: минимизация MSE — это ММП при нормальном шуме с постоянной дисперсией, минимизация log-loss — ММП для бинарного отклика (логистическая регрессия).

ПРИМЕР

3 успеха из 10: $\ell(p) = 3 \ln p + 7 \ln(1-p)$; $\ell'(p) = 3/p - 7/(1-p) = 0 \Rightarrow \hat{p} = 0,3$ (рис. 8).

PYTHON

```
stats.norm.fit(x) # ОМП  $\mu$  и  $\sigma$   
optimize.minimize(lambda t: -loglik(t, x), x0=t0) # в общем случае
```

СВЯЗИ

[правдоподобие](#) · [оценка](#) · [логистическая регрессия](#) · [log-loss](#) · [StatQuest](#)




Рис. 8. Функция правдоподобия для 3 успехов в 10 испытаниях. Максимум — в точке $\hat{p} = 0,3$.

Метод моментов method of moments

ОПРЕДЕЛЕНИЕ

Оценки получают, приравнявая теоретические моменты распределения, выраженные через параметры, к выборочным: $E_{\theta} X^k = \frac{1}{n} \sum_i x_i^k$ для $k = 1, 2, \dots$ (столько уравнений, сколько параметров), и решая систему относительно θ .

ПОЯСНЕНИЕ

Простой и быстрый способ; оценки обычно состоятельны, но менее эффективны, чем ОМП. Часто служат начальным приближением для численной максимизации правдоподобия.

ПРИМЕР

равномерное распределение $U(0; \theta)$: $EX = \theta/2 = \bar{x} \Rightarrow \hat{\theta} = 2\bar{x}$ (ОМП здесь другая: $\max_i x_i$).

СВЯЗИ

[ММП](#) · [оценка](#)

Доверительный интервал confidence interval (CI), confidence level $1 - \alpha$

ОПРЕДЕЛЕНИЕ

Доверительный интервал уровня доверия $1 - \alpha$ для параметра θ — интервал $[L(X); U(X)]$, границы которого — статистики, а вероятность накрыть истинное значение не меньше $1 - \alpha$ при любом θ : $P_{\theta}(L(X) \leq \theta \leq U(X)) \geq 1 - \alpha$. Если это выполняется лишь в пределе при $n \rightarrow \infty$, интервал называют асимптотическим.

ФОРМУЛЫ

$$\mu: \bar{x} \pm t_{1-\alpha/2}(n-1) \frac{s}{\sqrt{n}}; \quad p: \hat{p} \pm z_{1-\alpha/2} \sqrt{\frac{\hat{p}(1-\hat{p})}{n}}; \quad \mu_1 - \mu_2: \bar{x}_1 - \bar{x}_2 \pm t^* \sqrt{\frac{s_1^2}{n_1} + \frac{s_2^2}{n_2}}$$

ПОЯСНЕНИЕ

Случайны границы, а не параметр: при повторении эксперимента $\approx 95\%$ построенных 95%-х интервалов накроют θ (рис. 9). Интервал Вальда для доли плохо работает при p , близких к 0 или 1, и малых n — лучше интервал Уилсона. Для разности средних t^* берут с числом степеней свободы по Уэлчу. Двойственность: если интервал получен обращением критерия (t-интервал и t-критерий с одной и той же SE), 95%-й ДИ не содержит θ_0 тогда и только тогда, когда этот двусторонний критерий отвергает $H_0: \theta = \theta_0$ при $\alpha = 0,05$; при разных SE (z-критерий для двух долей с объединённой оценкой доли и интервал Вальда для их разности) выводы вблизи границы могут расходиться.

ПРИМЕР

$n = 100$, $\bar{x} = 50$, $s = 20$: $SE = 2$, $t_{0,975}(99) \approx 1,98$, 95%-й ДИ $\approx 50 \pm 3,97$, т. е. $[46,0; 54,0]$.

ЛОВУШКА

про уже построенный интервал нельзя сказать «параметр лежит в нём с вероятностью 95%»: 95% — свойство процедуры. Прямую вероятностную формулировку допускает байесовский интервал.

```
stats.t.interval(0.95, df=n - 1, loc=x.mean(), scale=stats.sem(x))
proportion_confint(k, n, alpha=0.05, method='wilson') # statsmodels
```




Рис. 9. Смысл уровня доверия: 40 выборок по 20 наблюдений из $N(50; 10^2)$ и 95%-е интервалы для μ . 38 из 40 интервалов накрыли истинное значение; при многократном повторении накрывают $\approx 95\%$.

Бутстрэп *bootstrap*

ОПРЕДЕЛЕНИЕ

Метод оценки выборочного распределения статистики по одной выборке: из исходной выборки $x_1, \dots, x_n$ многократно (B раз) извлекают выборки объёма n с возвращением и на каждой вычисляют статистику $\hat{\theta}^{*(b)}$; распределение этих значений приближает выборочное распределение $\hat{\theta}$.

ФОРМУЛЫ

$$\widehat{SE}_{boot} = \sqrt{\frac{1}{B-1} \sum_{b=1}^B (\hat{\theta}^{*(b)} - \bar{\theta}^*)^2}, \quad \text{перцентильный ДИ: } [\hat{\theta}_{(\alpha/2)}^*; \hat{\theta}_{(1-\alpha/2)}^*]$$

ПОЯСНЕНИЕ

Удобен, когда формулы для SE нет: медиана, квантили, отношения, метрики ML. Обычно $B = 1\,000\text{--}10\,000$. Не работает для экстремальных статистик (максимум) и ненадёжен на очень маленьких выборках. При зависимых наблюдениях бутстрэп-выборки формируют целыми блоками — пользователями, кластерами.

PYTHON

```
stats.bootstrap(x, np.median, n_resamples=9999, method='percentile') # по умолчанию
method='BCa'
```

5 Проверка гипотез

[этап 5 дорожной карты](#)

Как решить, объясняется ли наблюдаемое различие случайностью, и какой ценой ошибки.

Статистическая гипотеза: нулевая и альтернативная *statistical hypothesis, null H_0 , alternative H_1*

ОПРЕДЕЛЕНИЕ

Статистическая гипотеза — утверждение о распределении наблюдаемых величин (например, о значении параметра). Нулевая гипотеза H_0 — проверяемое утверждение, обычно об отсутствии эффекта ($\mu_1 = \mu_2$); альтернативная H_1 — утверждение, которое принимают при отклонении H_0 : двусторонняя ($\mu_1 \neq \mu_2$) или односторонняя ($\mu_1 > \mu_2$). Простая гипотеза полностью задаёт распределение, сложная — семейство распределений.

ПОЯСНЕНИЕ

Результат проверки — «отвергаем H_0 » или «нет оснований отвергнуть H_0 ». Не отвергнуть H_0 не значит доказать её: эффекта может не быть, а может не хватать данных (мощности). Гипотезы и направление альтернативы формулируют до получения данных.

ОПРЕДЕЛЕНИЕ

Проверка гипотезы — процедура принятия решения по данным, при которой вероятность ошибочно отвергнуть верную H_0 не превышает α . Шаги:

1. Сформулировать H_0 и H_1 (одно- или двустороннюю) до сбора данных.
2. Выбрать уровень значимости α (обычно 0,05), а при планировании — мощность и объём выборки.
3. Выбрать критерий по типу данных и дизайну ([таблица «Какой критерий выбрать»](#)) и проверить его предположения: независимость наблюдений, тип шкалы, нормальность или достаточный объём, равенство дисперсий.
4. Вычислить по данным статистику критерия $t_{\text{набл}}$.
5. Найти p-value (или сравнить $t_{\text{набл}}$ с критическим значением).
6. При $p \leq \alpha$ отвергнуть H_0 . Сообщить размер эффекта и доверительный интервал; при нескольких проверках — сделать поправку на множественные сравнения.

ПРИМЕР

новый дизайн кнопки. Контроль: 1 000 покупок из 10 000 визитов (10,0%), тест: 1 100 из 10 000 (11,0%). H_0 : $p_A = p_B$, двусторонняя H_1 , $\alpha = 0,05$, z-критерий для долей: $z_{\text{набл}} \approx 2,31$, $p \approx 0,021 < 0,05$ — различие статистически значимо. Эффект +1,0 п. п. (+10% относительно контроля), 95%-й ДИ для разности [0,15; 1,85] п. п.

PYTHON

```
from statsmodels.stats.proportion import proportions_ztest, confint_proportions_2indep
z, p = proportions_ztest(count=[1100, 1000], nobs=[10000, 10000])
confint_proportions_2indep(1100, 10000, 1000, 10000, method='wald')
```

СВЯЗИ

[гипотезы \$H_0\$ и \$H_1\$](#) · [z-критерий для долей](#) · [p-value](#) · [мощность](#) · [размер эффекта](#)

Критерий, статистика критерия, критическая область *statistical test, test statistic, critical region*

ОПРЕДЕЛЕНИЕ

Статистический критерий — правило, по которому по выборке принимают решение отвергнуть H_0 или нет. Обычно его задают статистикой критерия $T(X)$ — функцией выборки с известным при H_0 распределением — и критической областью K : H_0 отвергают, если $T(x) \in K$. Критическую область выбирают так, чтобы $P_{H_0}(T \in K) \leq \alpha$.

ПРИМЕР

двусторонний z-критерий при $\alpha = 0,05$: $K = \{|z| > 1,96\}$, так как $P(|Z| > 1,96) = 0,05$ для $Z \sim N(0; 1)$ (светлая заливка на [рис. 10](#)).

СВЯЗИ

[p-value](#) · [\$\chi^2\$, t и F](#) · [t-критерий](#)

p-value и уровень значимости *p-value, significance level α*

ОПРЕДЕЛЕНИЕ

Уровень значимости α — заданная заранее допустимая вероятность ошибки I рода. p-value (достигаемый уровень значимости) — вероятность при верной H_0 получить значение статистики критерия, не менее экстремальное в сторону альтернативы, чем наблюдаемое; это наименьший уровень значимости, при котором H_0 была бы отвергнута. H_0 отвергают, если $p \leq \alpha$.

ФОРМУЛЫ

$p = P_{H_0}(T \geq t_{\text{набл}})$ (правосторонняя альтернатива)
 $p = P_{H_0}(|T| \geq |t_{\text{набл}}|)$ (двусторонняя; распределение T симметрично)

ПРИМЕР

$z_{\text{набл}} = 2,4$, двусторонняя альтернатива: $p = 2 P(Z \geq 2,4) \approx 0,016$ ([рис. 10](#)).

ЛОВУШКА

p-value — не вероятность того, что H_0 верна, и не размер эффекта. Значения 0,04 и 0,06 почти не различаются по силе доказательств. Перебор анализов, метрик и подвыборок до получения $p < 0,05$ (p-hacking) делает вывод недостоверным.

СВЯЗИ

[мощность](#) · [размер эффекта](#) · [множественные сравнения](#) · [статистика критерия](#) · [► StatQuest: p-value](#) · [► p-hacking](#)




Рис. 10. p-value при двусторонней альтернативе — площадь обоих хвостов распределения статистики при H_0 за значениями $\pm|z|$. Критическая область при $\alpha = 0,05$ — $|z| > 1,96$.

Ошибки I и II рода, мощность *type I error (α), type II error (β), power $1 - \beta$*

ОПРЕДЕЛЕНИЕ

Ошибка I рода — отвергнуть H_0 , когда она верна (ложноположительный вывод); её вероятность ограничена уровнем значимости α . Ошибка II рода — не отвергнуть H_0 , когда верна H_1 (ложноотрицательный вывод); её вероятность обозначают β . Мощность критерия $1 - \beta = P_{H_1}$ (отвергнуть H_0) — вероятность обнаружить эффект, если он есть; она зависит от истинной величины эффекта.

СХЕМА

	H_0 верна	H_0 неверна (верна H_1)
H_0 отвергнута	ошибка I рода, вероятность α	верное решение, вероятность $1 - \beta$ (мощность)
H_0 не отвергнута	верное решение, вероятность $1 - \alpha$	ошибка II рода, вероятность β

ФОРМУЛЫ

$$1 - \beta \approx \Phi(\delta - z_{1-\alpha/2}), \quad \delta = \frac{|\text{эффект}|}{\text{SE}} \quad (\text{двусторонний z-критерий})$$

ПОЯСНЕНИЕ

Мощность растёт с размером эффекта, объёмом выборки и α и падает с ростом дисперсии данных. При $\alpha = 0,05$ и эффекте $\delta = 2,8$ стандартной ошибки мощность $\approx 0,80$ (рис. 11) — поэтому эксперименты планируют так, чтобы ожидаемый эффект составлял около $2,8 \text{ SE}$.

PYTHON

```
TTestIndPower().power(effect_size=0.5, nobs1=64, alpha=0.05) # ≈ 0,80; statsmodels.stats.power
```

СВЯЗИ

MDE · размер эффекта · p-value · [StatQuest](#)




Рис. 11. Ошибки и мощность двустороннего z-критерия при $\alpha = 0,05$: если истинный эффект равен $2,8$ стандартной ошибки, мощность $\approx 0,80$.

Размер эффекта *effect size: Cohen's d, η^2 , Cramér's V*

ОПРЕДЕЛЕНИЕ

Размер эффекта — мера величины различия или силы связи, не зависящая от объёма выборки. Его выражают в исходных единицах (разность средних, прирост конверсии в п. п. или %) или в стандартизованном виде.

ФОРМУЛЫ

$$d = \frac{\bar{x}_1 - \bar{x}_2}{s_p}, \quad s_p = \sqrt{\frac{(n_1 - 1)s_1^2 + (n_2 - 1)s_2^2}{n_1 + n_2 - 2}}, \quad \eta^2 = \frac{SS_B}{SS_T}, \quad V = \sqrt{\frac{\chi^2}{n(\min(r, c) - 1)}}$$

ПОЯСНЕНИЕ

При большом n значимым оказывается и ничтожный эффект: статистическая значимость $\neq$ практическая важность. Сообщайте эффект вместе с доверительным интервалом. Ориентиры Коэна для $|d|$: 0,2 — малый, 0,5 — средний, 0,8 — большой (условные, зависят от области).

СВЯЗИ

p-value · доверительный интервал · MDE · ANOVA · критерий χ^2

z-критерий для долей two-proportion z-test

ОПРЕДЕЛЕНИЕ	Критерий для проверки $H_0: p_1 = p_2$ по двум независимым выборкам с долями успехов $\hat{p}_1 = k_1/n_1$ и $\hat{p}_2 = k_2/n_2$. При H_0 статистика приближённо имеет распределение $N(0; 1)$ (по ЦПТ).
ФОРМУЛЫ	$z = \frac{\hat{p}_1 - \hat{p}_2}{\sqrt{\hat{p}(1 - \hat{p}) \left(\frac{1}{n_1} + \frac{1}{n_2} \right)}}, \quad \hat{p} = \frac{k_1 + k_2}{n_1 + n_2}$
ПРИМЕНЕНИЕ	Сравнение конверсий, CTR и других долей в А/В-тестах при достаточно больших выборках (ориентир: $n\hat{p} \geq 10$ и $n(1 - \hat{p}) \geq 10$ в каждой группе). Эквивалентен критерию χ^2 для таблицы 2×2 без поправки Йейтса: $z^2 = \chi^2$. При малых частотах — точный критерий Фишера.
ПРИМЕР	пример из статьи «Схема проверки гипотезы»: $\hat{p} = 2100/20000 = 0,105$, $SE = \sqrt{0,105 \cdot 0,895 \cdot 2/10000} \approx 0,004335$, $z = 0,01/0,004335 \approx 2,31$, $p \approx 0,021$.
PYTHON	<code>proportions_ztest(count=[1100, 1000], nobs=[10000, 10000]) # statsmodels.stats.proportion</code>
СВЯЗИ	критерий χ^2 · А/В-тест · t-критерий · доверительный интервал

t-критерии Стьюдента и Уэлча one-sample, two-sample (Student's, Welch's) and paired t-tests

ОПРЕДЕЛЕНИЕ	Критерии для средних, статистика которых при H_0 и нормальных данных имеет распределение Стьюдента (у критерия Уэлча — приближённо). Одновыборочный проверяет $H_0: \mu = \mu_0$; двухвыборочный — $H_0: \mu_1 = \mu_2$ для независимых выборок (критерий Стьюдента предполагает равные дисперсии, критерий Уэлча — нет); парный — $H_0: \mu_d = 0$ для разностей $d_i = x_i - y_i$ парных измерений.
ФОРМУЛЫ	одновыборочный: $t = \frac{\bar{x} - \mu_0}{s/\sqrt{n}}$, $\nu = n - 1$; Стьюдента: $t = \frac{\bar{x}_1 - \bar{x}_2}{s_p \sqrt{1/n_1 + 1/n_2}}$, $\nu = n_1 + n_2 - 2$ Уэлча: $t = \frac{\bar{x}_1 - \bar{x}_2}{\sqrt{s_1^2/n_1 + s_2^2/n_2}}$, $\nu \approx \frac{(s_1^2/n_1 + s_2^2/n_2)^2}{\frac{(s_1^2/n_1)^2}{n_1 - 1} + \frac{(s_2^2/n_2)^2}{n_2 - 1}}$; парный: $t = \frac{\bar{d}}{s_d/\sqrt{n}}$, $\nu = n - 1$
ПРИМЕНЕНИЕ	Сравнение средних значений количественного признака: средний чек в двух группах, время до и после изменения (парный). Предположения: независимые наблюдения; нормальность совокупности или достаточно большой объём (ЦПТ). Для двух групп разумно по умолчанию брать критерий Уэлча.
ЛОВУШКА	t-критерии чувствительны к выбросам и тяжёлым хвостам (выручка, время): среднее и s «раздуваются». Помогают логарифмирование, бутстрэп или ранговые критерии. Для парных данных нельзя применять двухвыборочный критерий: он игнорирует связь пар и теряет мощность.
PYTHON	<code>stats.ttest_1samp(x, popmean=mu0); stats.ttest_ind(a, b, equal_var=False) # Уэлч</code> <code>stats.ttest_rel(before, after) # парный</code>
СВЯЗИ	статистика критерия · ЦПТ · Манна-Уитни · ANOVA · QQ-график · StatQuest: t-тесты и ANOVA

Проверка нормальности, QQ-график normality tests (Shapiro-Wilk), Q-Q plot

ОПРЕДЕЛЕНИЕ	QQ-график (квантиль-квантильный) — диаграмма, на которой выборочные квантили отложены против квантилей теоретического распределения (обычно нормального); если данные из этого распределения, точки лежат около прямой. Критерий Шапиро-Уилка проверяет H_0 : выборка извлечена из нормального распределения.
ФОРМУЛА	$W = \frac{\left(\sum_{i=1}^n a_i x_{(i)} \right)^2}{\sum_{i=1}^n (x_i - \bar{x})^2}$
ПОЯСНЕНИЕ	$x_{(1)} \leq \dots \leq x_{(n)}$ — упорядоченные наблюдения, a_i — константы, вычисляемые по средним и ковариациям порядковых статистик выборки объёма n из $N(0; 1)$; $W \leq 1$, малые значения W — свидетельство против нормальности. Изгиб QQ-графика указывает на асимметрию, S-образная форма — на тяжёлые или лёгкие хвосты (рис. 12). На больших выборках критерии нормальности отвергают H_0 из-за практически неважных отклонений, а на малых не замечают серьёзных; поэтому смотрите на график и на то, насколько выбранный метод устойчив к отклонениям.

ПРИМЕНЕНИЕ	Проверка предположений t-критериев, ANOVA и линейной регрессии (нормальность остатков).
PYTHON	<code>stats.shapiro(x); stats.probplot(x, dist='norm', plot=plt); sm.qqplot(resid, line='s')</code>
СВЯЗИ	t-критерий · остатки




Рис. 12. QQ-графики по 120 наблюдений: у нормальных данных точки лежат на прямой (критерий Шапиро-Уилка: $p \approx 0,50$), у скошенных вправо изгибаются дугой ($p < 0,001$).

Непараметрические критерии Mann-Whitney U, Wilcoxon signed-rank, permutation test

ОПРЕДЕЛЕНИЕ	Непараметрические критерии не предполагают, что распределение принадлежит конкретному параметрическому семейству. Критерий Манна-Уитни сравнивает две независимые выборки по рангам наблюдений в объединённой выборке. Критерий знаковых рангов Уилкоксона — аналог парного t-критерия: ненулевые разности d_i ранжируют по модулю и складывают ранги положительных разностей; H_0 — распределение разностей симметрично относительно нуля. Перестановочный тест строит распределение статистики при H_0 , многократно случайно переставляя метки групп.
ФОРМУЛЫ	$U_1 = R_1 - \frac{n_1(n_1 + 1)}{2}, \quad W^+ = \sum_{i: d_i > 0} \text{rank } d_i $ $p_{\text{перест}} = \frac{\#\{b: T^{*(b)} \geq T_{\text{набл}} \} + 1}{B + 1}$
ПОЯСНЕНИЕ	R_1 — сумма рангов первой выборки в объединённой; $T^{*(b)}$ — значение статистики на перестановке номер b ($b = 1, \dots, B$). p-value критерия Манна-Уитни вычисляют в предположении H_0 : распределения в группах одинаковы; критерий чувствителен к отклонениям вида $P(X > Y) \neq P(X < Y)$. Если распределения различаются формой или разбросом, вероятность ошибки I рода при проверке $P(X > Y) = P(X < Y)$ может превышать α — тогда используют критерий Бруннера-Мюнцеля. Как сравнение медиан результат можно трактовать, только если распределения отличаются лишь сдвигом.
ПРИМЕНЕНИЕ	Порядковые данные, малые выборки, сильная асимметрия или выбросы, когда нормальное приближение сомнительно.
PYTHON	<code>stats.mannwhitneyu(a, b, alternative='two-sided'); stats.brunnermunzel(a, b)</code> <code>stats.wilcoxon(before, after) # d = before - after; при two-sided statistic = min(W+, W-)</code> <code>stats.permutation_test((a, b), lambda u, v: np.mean(u) - np.mean(v), n_resamples=9999)</code>

СВЯЗИ [t-критерий](#) · [корреляция Спирмена](#) · [Краскел-Уоллис](#)

Множественные сравнения multiple comparisons: FWER, FDR

ОПРЕДЕЛЕНИЕ	Проблема множественных сравнений — рост вероятности хотя бы одной ложной находки при проверке многих гипотез. FWER — вероятность хотя бы одной ошибки I рода среди m проверок. FDR — ожидаемая доля ложных отклонений среди всех отвергнутых гипотез: $\text{FDR} = E[V / \max(R, 1)],$ где V — число ложных отклонений, R — число всех отклонений.
ФОРМУЛЫ	Бонферрони: $p_i \leq \frac{\alpha}{m}$; Холм: $p_{(k)} \leq \frac{\alpha}{m - k + 1}$; Бенджамини-Хохберг: $p_{(k)} \leq \frac{k}{m} \alpha$
ПОЯСНЕНИЕ	При m независимых проверках верных H_0 вероятность хотя бы одной ошибки равна $1 - (1 - \alpha)^m$: для $m = 20$ и $\alpha = 0,05 \approx 64\%$. $p_{(1)} \leq \dots \leq p_{(m)}$ — упорядоченные p-value. Холм: идут по возрастанию и отвергают, пока условие выполняется (мощнее Бонферрони, тоже контролирует FWER). Бенджамини-Хохберг: находят наибольшее k с $p_{(k)} \leq k\alpha/m$ и отвергают $H_{(1)}, \dots, H_{(k)}$ (контролирует FDR на уровне α при независимых или положительно зависимых p-value).

ПРИМЕНЕНИЕ	FWER — когда важна каждая ошибка: несколько метрик или групп в A/B-тесте, попарные сравнения после ANOVA. FDR — при массовом поиске: тысячи генов, признаков, сегментов.
PYTHON	<pre>multipletests(pvals, alpha=0.05, method='holm') # 'bonferroni', 'fdr_bh'; statsmodels.stats.multitest</pre>
СВЯЗИ	p-value · ANOVA · A/B-тест · ► StatQuest

6

Несколько групп и таблицы сопряжённости

этап 6 дорожной карты

Сравнение трёх и более групп, связь категориальных признаков и сводная таблица выбора критерия.

Однофакторный дисперсионный анализ (ANOVA)

one-way analysis of variance (ANOVA)

ОПРЕДЕЛЕНИЕ	Критерий для проверки $H_0: \mu_1 = \mu_2 = \dots = \mu_k$ для $k \geq 2$ независимых групп. Общая сумма квадратов отклонений раскладывается на межгрупповую (разброс средних групп вокруг общего среднего) и внутригрупповую. Их нормированное отношение F при H_0 , нормальности внутри групп и равных дисперсиях имеет распределение Фишера $F(k - 1, N - k)$, где $N = \sum_j n_j$.
ФОРМУЛЫ	$SS_T = SS_B + SS_W, \quad SS_B = \sum_{j=1}^k n_j (\bar{x}_j - \bar{x})^2, \quad SS_W = \sum_{j=1}^k \sum_{i=1}^{n_j} (x_{ij} - \bar{x}_j)^2$ $F = \frac{SS_B / (k - 1)}{SS_W / (N - k)} \sim F(k - 1, N - k) \text{ при } H_0, \quad \eta^2 = \frac{SS_B}{SS_T}$
ПОЯСНЕНИЕ	Значимый F говорит лишь о том, что отличается хотя бы одна группа; какие именно — покажут попарные сравнения с поправкой (post hoc, критерий Тьюки). Предположения: независимость, нормальность внутри групп (или большие n_j), равные дисперсии; при неравных — ANOVA Уэлча. При $k = 2$ ANOVA эквивалентен t -критерию Стьюдента: $F = t^2$.
ПРИМЕР	три группы по 15 наблюдений (рис. 13): $F \approx 29,0$ при $(2; 42)$ степенях свободы, $p < 0,001$, $\eta^2 \approx 0,58$ — различия между группами объясняют 58% общей изменчивости.
PYTHON	<pre>stats.f_oneway(a, b, c) pairwise_tukeyhsd(endog=y, groups=g) # statsmodels.stats.multicomp</pre>
СВЯЗИ	χ², t и F · множественные сравнения · Краскел–Уоллис · размер эффекта · ► StatQuest




Рис. 13. Однофакторный ANOVA: межгрупповой разброс (средние групп вокруг общего среднего) велик по сравнению с внутригрупповым, поэтому статистика F большая.

Критерий Краскела–Уоллиса

Kruskal–Wallis H test

ОПРЕДЕЛЕНИЕ	Ранговый аналог однофакторного ANOVA для $k \geq 2$ независимых групп: все N наблюдений ранжируют вместе и сравнивают средние ранги групп; при H_0 (распределения во всех группах одинаковы) статистика H приближённо имеет распределение $\chi^2(k - 1)$.
ФОРМУЛА	$H = \frac{12}{N(N + 1)} \sum_{j=1}^k \frac{R_j^2}{n_j} - 3(N + 1)$
ПОЯСНЕНИЕ	R_j — сумма рангов группы j (формула без поправки на совпадения). После значимого результата — попарные сравнения (критерий Данна) с поправкой на множественность.

PYTHON

stats.kruskal(a, b, c)

СВЯЗИ

ANOVA · Манна–Уитни

Таблица сопряжённости и критерий χ^2 независимости

contingency table, chi-squared test of independence

ОПРЕДЕЛЕНИЕ	Таблица сопряжённости — таблица частот O_{ij} совместных значений двух категориальных признаков (r строк, c столбцов). Критерий χ^2 проверяет H_0 : признаки независимы — сравнивая наблюдаемые частоты с ожидаемыми при независимости E_{ij} .
ФОРМУЛЫ	$\chi^2 = \sum_{i=1}^r \sum_{j=1}^c \frac{(O_{ij} - E_{ij})^2}{E_{ij}}, \quad E_{ij} = \frac{R_i C_j}{N}, \quad \nu = (r - 1)(c - 1)$
ПОЯСНЕНИЕ	R_i, C_j — итоги строки и столбца, N — общее число наблюдений. Приближение χ^2 требует не слишком малых ожидаемых частот (ориентир: все $E_{ij} \geq 5$); для таблиц 2×2 с малыми частотами — точный критерий Фишера. Для таблицы 2×2 SciPy по умолчанию применяет поправку Йейтса на непрерывность. Сила связи — V Крамера.
ПРИМЕР	покупка: A — 100 из 1 000, B — 150 из 1 000. Ожидаемые частоты: 125 покупок и 875 без покупки в каждой группе; $\chi^2 \approx 11,4$ (с поправкой Йейтса 11,0), $\nu = 1, p < 0,001$.
PYTHON	<pre>pd.crosstab(df['group'], df['bought']); stats.chi2_contingency(table) # 2x2: с поправкой Йейтса stats.fisher_exact(table)</pre>
СВЯЗИ	типы данных · z-критерий для долей · критерий согласия · размер эффекта

Критерий согласия χ^2

chi-squared goodness-of-fit test

ОПРЕДЕЛЕНИЕ	Критерий проверяет H_0 : вероятности k категорий равны $p_1, \dots, p_k$ — заданным числам или значениям $p_i(\theta)$ модели с неизвестными параметрами θ . Наблюдаемые частоты $O_1, \dots, O_k$ ($O_1 + \dots + O_k = n$) сравнивают с частотами $E_i = np_i$, ожидаемыми при H_0 .
ФОРМУЛА	$\chi^2 = \sum_{i=1}^k \frac{(O_i - E_i)^2}{E_i} \stackrel{a}{\sim} \chi^2(k - 1 - m) \text{ при } H_0$
ПОЯСНЕНИЕ	$\stackrel{a}{\sim}$ — «асимптотически (при $n \rightarrow \infty$) имеет распределение»; приближение считают приемлемым, если все $E_i \geq 5$. m — число параметров θ , оценённых по тем же данным (в E_i подставляют $p_i(\hat{\theta})$); если p_i заданы полностью, $m = 0$. Для непрерывных распределений вместо разбиения на интервалы часто используют критерий Колмогорова–Смирнова (для полностью заданного распределения).
ПРИМЕНЕНИЕ	Проверка равномерности (например, по дням недели), соответствия модели и SRM в A/B-тесте: при плане 50/50 группы 50 600 и 49 400 дают $\chi^2 = 14,4, p \approx 0,00015$ — разбиение трафика сломано.
PYTHON	<pre>stats.chisquare(f_obs=[50600, 49400], f_exp=[50000, 50000]) # SRM: ожидаемые частоты при 50/50 stats.kstest(x, 'norm', args=(mu, sigma)) # Колмогоров–Смирнов, параметры заданы заранее</pre>
СВЯЗИ	критерий χ^2 · A/B-тест

Какой критерий выбрать

сводная таблица: задача и тип данных → параметрический критерий → непараметрический или точный аналог

ЗАДАЧА И ДАННЫЕ	ПАРАМЕТРИЧЕСКИЙ КРИТЕРИЙ	НЕПАРАМЕТРИЧЕСКИЙ / ТОЧНЫЙ АНАЛОГ	PYTHON
Центр одной выборки и заданное значение: среднее μ_0 или медиана m_0	одновыборочный t-критерий	знаковых рангов Уилкоксона (о медиане — при симметричном распределении); знаковый критерий	<code>ttest_1samp(x, mu0)</code> , <code>wilcoxon(x - m0)</code> , <code>binomtest(k, n)</code> (знаковый: <code>k = (x > m0).sum()</code> , <code>n = (x != m0).sum()</code>)
Две независимые группы, количественный признак	t-критерий Уэлча	Манна-Уитни; Бруннера-Мюнцеля (при разной форме распределений); перестановочный тест	<code>ttest_ind(a, b, equal_var=False)</code> , <code>mannwhitneyu(a, b)</code> , <code>brunnermunzel(a, b)</code>
Два связанных измерения одних объектов (до / после)	парный t-критерий	знаковых рангов Уилкоксона	<code>ttest_rel(a, b)</code> , <code>wilcoxon(a, b)</code>
Три и более независимые группы	однофакторный ANOVA (Уэлча при разных дисперсиях)	Краскела-Уоллиса	<code>f_oneway(a, b, c)</code> , <code>f_oneway(a, b, c, equal_var=False)</code> (Уэлч), <code>kruskal(a, b, c)</code>
Три и более связанных измерения	ANOVA с повторными измерениями	Фридмана	<code>AnovaRM</code> , <code>friedmanchisquare(a, b, c)</code>
Две доли (конверсии), большие выборки	z-критерий для долей ($= \chi^2$ для 2×2)	точный критерий Фишера (малые частоты)	<code>proportions_ztest(k, n)</code> , <code>fisher_exact(t)</code>
Связь двух категориальных признаков	χ^2 независимости	точный критерий Фишера (малые частоты)	<code>chi2_contingency(t)</code> , <code>fisher_exact(t)</code>
Связь двух количественных признаков	t-критерий для r Пирсона	Спирмена, Кендалла	<code>pearsonr</code> , <code>spearmanr</code> , <code>kendalltau</code>
Частоты категорий и заданные доли (в т. ч. SRM)	χ^2 согласия	точный биномиальный / мультиномиальный	<code>chisquare(obs, f_exp=exp)</code> , <code>binomtest(k, n, p)</code>
Нормальность распределения	—	Шапиро-Уилка; QQ-график	<code>shapiro(x)</code> , <code>probplot(x)</code>
Равенство дисперсий групп	F-критерий (чувствителен к ненормальности)	Левена / Брауна-Форсайта	<code>levene(a, b)</code> (по умолчанию — вариант Брауна-Форсайта)
Две модели на одних объектах: доли верных ответов	—	Мак-Немара	<code>mcnemar(table)</code> (<code>statsmodels</code>)
Любая статистика без известного распределения	—	бутстрэп, перестановочный тест	<code>bootstrap</code> , <code>permutation_test</code>

Функции без префикса — из `scipy.stats`; `proportions_ztest`, `AnovaRM` и `mcnemar` — из `statsmodels`. В `chisquare` передают ожидаемые частоты, а не доли: `exp = obs.sum() * np.array(p)`. Параметрические критерии предполагают нормальность (или достаточный объём выборки) и независимость наблюдений. Непараметрические не требуют нормальности, но тоже предполагают независимость и проверяют другие гипотезы: ранговые (Манна-Уитни, Краскела-Уоллиса) и перестановочные — одинаковость распределений (в модели сдвига — равенство медиан), Бруннера-Мюнцеля — $P(X > Y) = P(X < Y)$, знаковых рангов — симметрию разностей относительно нуля.

7

Регрессия и её оптимизация

этап 7 дорожной карты

Как описать зависимость отклика от признаков, как найти коэффициенты и что из них можно (и нельзя) выводить.

Модель линейной регрессии *linear regression model*

ОПРЕДЕЛЕНИЕ	Модель зависимости отклика y от признаков $x_1, \dots, x_p$: $y_i = \beta_0 + \beta_1 x_{i1} + \dots + \beta_p x_{ip} + \varepsilon_i$, где ε_i — случайные ошибки. В матричной форме $y = X\beta + \varepsilon$, где X — матрица размера $n \times (p + 1)$ с первым столбцом из единиц.
ПОЯСНЕНИЕ	Классические предположения: (1) линейность по параметрам; (2) $E\varepsilon_i = 0$; (3) гомоскедастичность $\text{Var } \varepsilon_i = \sigma^2$; (4) некоррелированность ошибок; (5) столбцы X линейно независимы (нет строгой мультиколлинеарности); для точных t- и F-критериев — (6) нормальность ошибок. Коэффициент β_j — ожидаемое изменение y при росте x_j на единицу при фиксированных остальных признаках. Модель линейна по параметрам, а не по признакам: в неё можно включать x^2 , $\ln x$ и произведения признаков.

ЛОВУШКА

значимый коэффициент — ещё не причинный эффект: без рандомизации связь может создаваться неучтённым конфаундером или обратной причинностью.

СВЯЗИ

МНК · [остатки](#) · [значимость коэффициентов](#) · [конфаундер](#) · [► StatQuest](#)

Метод наименьших квадратов (МНК) *ordinary least squares (OLS)*

ОПРЕДЕЛЕНИЕ

МНК-оценка — значение β , минимизирующее сумму квадратов остатков $RSS(\beta) = \sum_i (y_i - x_i^\top \beta)^2 = \|y - X\beta\|^2$. Приравнивание градиента к нулю даёт нормальные уравнения $X^\top X \hat{\beta} = X^\top y$; при линейно независимых столбцах X решение единственно.

ФОРМУЛЫ

$$\hat{\beta} = (X^\top X)^{-1} X^\top y; \quad \text{один признак: } \hat{\beta}_1 = \frac{s_{xy}}{s_x^2} = r \frac{s_y}{s_x}, \quad \hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x}$$

ПОЯСНЕНИЕ

Прямая МНК проходит через точку средних $(\bar{x}; \bar{y})$, сумма остатков равна нулю ([рис. 14](#)). Теорема Гаусса–Маркова: при предположениях (1)–(5) МНК-оценка имеет наименьшую дисперсию среди линейных несмещённых оценок (BLUE). При нормальных ошибках МНК совпадает с ММП. Дисперсию ошибок оценивают как $\hat{\sigma}^2 = RSS/(n - p - 1)$.

ЛОВУШКА

матрицу $(X^\top X)^{-1}$ на практике явно не вычисляют: библиотеки решают задачу через QR- или SVD-разложение — это устойчивее при почти коллинеарных признаках.

PYTHON

```
smf.ols('y ~ x1 + x2', data=df).fit().summary()
np.linalg.lstsq(X, y, rcond=None); LinearRegression().fit(X, y)
```

СВЯЗИ

[линейная регрессия](#) · [градиентный спуск](#) · R^2 · [значимость коэффициентов](#) · [ММП](#)




Рис. 14. МНК-прямая по 25 точкам: сумма квадратов вертикальных отрезков — остатков — минимальна. Прямая проходит через точку средних.

Градиентный спуск *gradient descent (GD), stochastic gradient descent (SGD)*

ОПРЕДЕЛЕНИЕ

Итерационный метод минимизации дифференцируемой функции потерь $L(\beta)$: на каждом шаге параметры сдвигают против градиента, $\beta^{(t+1)} = \beta^{(t)} - \eta \nabla L(\beta^{(t)})$, где $\eta > 0$ — шаг обучения (learning rate). Стохастический градиентный спуск (SGD) вычисляет градиент по одному случайному объекту или небольшой случайной подвыборке (мини-батчу) вместо всей выборки.

ФОРМУЛЫ

$$L(\beta) = \frac{1}{n} \|y - X\beta\|^2, \quad \nabla L(\beta) = -\frac{2}{n} X^\top (y - X\beta), \quad \beta^{(t+1)} = \beta^{(t)} + \frac{2\eta}{n} X^\top (y - X\beta^{(t)})$$

ПОЯСНЕНИЕ

MSE — выпуклая функция, и при $0 < \eta < 2/\lambda_{\max}$, где $\lambda_{\max}$ — наибольшее собственное число матрицы $\frac{2}{n} X^\top X$, спуск сходится к решению МНК. Скорость зависит от числа обусловленности $\lambda_{\max}/\lambda_{\min}$: у признаков разного масштаба линии уровня — вытянутые эллипсы, и спуск идёт зигзагом; после стандартизации признаков он сходится во много раз быстрее ([рис. 15](#)). Слишком большой шаг ведёт к расхождению, слишком маленький — к медленной сходимости.

ПРИМЕНЕНИЕ

Когда закрытой формулы нет или она дорога: логистическая регрессия, нейросети; очень большие n и p (формула МНК требует порядка $np^2 + p^3$ операций); потоковые данные — SGD обновляет модель по мере поступления объектов. Для lasso обычно используют родственный метод — координатный спуск.

ПРИМЕР

на данных [рис. 15](#) с одним и тем же шагом $\eta \approx 0,14$ спуск приходит к решению МНК (с точностью 0,01) за 86 шагов при исходном $x \in [0; 4]$ и за 21 шаг после стандартизации: число обусловленности падает с ≈ 30 до 1.

PYTHON

```
for _ in range(n_iter): beta += eta * 2 / n * X.T @ (y - X @ beta) # полный градиентный спуск
make_pipeline(StandardScaler(), SGDRegressor(eta0=0.01)).fit(X, y)
```




Рис. 15. Градиентный спуск для MSE с одним и тем же шагом $\eta \approx 0,14$. Слева признак в исходном масштабе: линии уровня вытянуты, путь идёт зигзагом, до минимума 86 шагов. Справа признак стандартизован: линии уровня — окружности, путь прямой, 21 шаг.

Значимость коэффициентов и модели *standard errors, t-tests and F-test in regression*

ОПРЕДЕЛЕНИЕ

Для проверки $H_0: \beta_j = 0$ используют t-статистику — оценку коэффициента, делённую на её стандартную ошибку; при H_0 и независимых нормальных ошибках с постоянной дисперсией она имеет распределение $t(n - p - 1)$. F-критерий проверяет $H_0: \beta_1 = \dots = \beta_p = 0$ — модель не лучше константы.

ФОРМУЛЫ

$$SE(\hat{\beta}_j) = \hat{\sigma} \sqrt{[(X^T X)^{-1}]_{jj}}, \quad t_j = \frac{\hat{\beta}_j}{SE(\hat{\beta}_j)}, \quad \hat{\beta}_j \pm t_{1-\alpha/2}(n - p - 1) SE(\hat{\beta}_j)$$
$$F = \frac{(TSS - RSS)/p}{RSS/(n - p - 1)} \sim F(p, n - p - 1) \text{ при } H_0$$

ПОЯСНЕНИЕ

$TSS = \sum (y_i - \bar{y})^2$ — общая сумма квадратов. При гетероскедастичности обычные SE неверны — используют робастные (в statsmodels `cov_type='HC3'`). Значимость коэффициента зависит от того, какие ещё признаки есть в модели.

PYTHON

```
res = smf.ols('y ~ x1 + x2', data=df).fit()
res.params; res.bse; res.pvalues; res.conf_int(); res.fvalue, res.f_pvalue
```

СВЯЗИ

МНК · R^2 · остатки · χ^2 , t и F

Коэффициент детерминации R^2 *coefficient of determination R^2 , adjusted R^2*

ОПРЕДЕЛЕНИЕ

Доля дисперсии отклика, объяснённая моделью: единица минус отношение остаточной суммы квадратов к общей. Скорректированный R^2 учитывает число признаков p .

ФОРМУЛЫ

$$R^2 = 1 - \frac{RSS}{TSS} = 1 - \frac{\sum (y_i - \hat{y}_i)^2}{\sum (y_i - \bar{y})^2}, \quad R^2_{adj} = 1 - (1 - R^2) \frac{n - 1}{n - p - 1}$$

ПОЯСНЕНИЕ

Для МНК со свободным членом на обучающих данных $0 \leq R^2 \leq 1$, а в простой регрессии $R^2 = r^2$. R^2 не убывает при добавлении любых признаков, поэтому модели сравнивают по R^2_{adj} , информационным критериям (AIC, BIC) или на валидации. На новых данных R^2 может быть отрицательным — модель хуже константы $\bar{y}$.

ЛОВУШКА

высокий R^2 не доказывает правильность модели и причинность; низкий не обесценивает значимые коэффициенты: в поведенческих данных $R^2 = 0,1$ — обычное дело.

PYTHON

```
res.rsquared; res.rsquared_adj; sklearn.metrics.r2_score(y_true, y_pred)
```

СВЯЗИ

корреляция · МНК · кросс-валидация · метрики регрессии · ► StatQuest

ОПРЕДЕЛЕНИЕ

Остаток — разность наблюдения и прогноза: $e_i = y_i - \hat{y}_i$. Диагностика регрессии — проверка предположений модели по остаткам: если они выполнены, график остатков против прогноза $\hat{y}$ — облако без структуры с постоянным разбросом. Мультиколлинеарность — сильная линейная связь между признаками; её меру для признака x_j даёт коэффициент увеличения дисперсии VIF.

ФОРМУЛА

$$VIF_j = \frac{1}{1 - R_j^2}$$

ПОЯСНЕНИЕ

Изгиб на графике остатков — пропущена нелинейность (добавьте x^2 , $\ln x$, взаимодействия); «воронка» — гетероскедастичность (робастные SE, преобразование y , критерий Бройша–Пагана); изгиб QQ-графика остатков — ненормальность (рис. 16). R_j^2 — коэффициент детерминации регрессии x_j на остальные признаки; $VIF > 5-10$ — повод насторожиться: коэффициенты неустойчивы, их SE раздуты. Влиятельные точки ищут по расстоянию Кука.

PYTHON

```
res.resid; res.fittedvalues; res.get_influence().cooks_distance
variance_inflation_factor(X, j); het_breuschpagan(res.resid, res.model.exog)
```

СВЯЗИ

[МНК](#) · [QQ-график](#) · [тепловая карта](#) · [регуляризация](#)




Рис. 16. Остатки против прогноза для трёх моделей: облако без структуры (предположения выполнены), дуга (пропущен квадратичный член), воронка (разброс ошибок растёт с прогнозом).

Регуляризация: гребневая регрессия и лассо regularization: ridge (L2), lasso (L1), elastic net

ОПРЕДЕЛЕНИЕ

Регуляризация — добавление к функции потерь штрафа за величину коэффициентов, уменьшающее переобучение. Гребневая регрессия (ridge) штрафует сумму квадратов коэффициентов, лассо (lasso) — сумму их модулей, эластичная сеть — комбинацию обоих штрафов. Свободный член не штрафуют.

ФОРМУЛЫ

$$\hat{\beta}_{\text{ridge}} = \arg \min_{\beta} \left(\|y - X\beta\|^2 + \lambda \sum_{j=1}^p \beta_j^2 \right) = (X^T X + \lambda I)^{-1} X^T y$$

$$\hat{\beta}_{\text{lasso}} = \arg \min_{\beta} \left(\frac{1}{2n} \|y - X\beta\|^2 + \lambda \sum_{j=1}^p |\beta_j| \right)$$

ПОЯСНЕНИЕ

Штраф увеличивает смещение, но снижает дисперсию оценок (компромисс смещения и разброса). Ridge сжимает все коэффициенты и устойчив при мультиколлинеарности; формула для него записана для центрированных X и y . Lasso обнуляет часть коэффициентов, то есть отбирает признаки; закрытой формулы нет, решают координатным спуском. Признаки перед регуляризацией стандартизуют, силу штрафа λ подбирают кросс-валидацией.

ЛОВУШКА

в sklearn сила штрафа называется `alpha`, а в `LogisticRegression` задаётся обратная величина `C = 1/lambda`, причём L2-регуляризация включена по умолчанию (`C=1.0`) — поэтому её коэффициенты отличаются от statsmodels.

PYTHON

```
make_pipeline(StandardScaler(), RidgeCV(alphas=np.logspace(-3, 3, 13))).fit(X, y)
make_pipeline(StandardScaler(), LassoCV(cv=5)).fit(X, y)
```

СВЯЗИ

[смещение и разброс](#) · [кросс-валидация](#) · [градиентный спуск](#) · [остатки](#) · [z-оценка](#)

Категориальные признаки и взаимодействия *dummy variables, one-hot encoding, interaction*

ОПРЕДЕЛЕНИЕ

Категориальный признак с k уровнями кодируют $k - 1$ фиктивными (индикаторными) переменными $D_j \in \{0, 1\}$; оставшийся уровень — базовый. Коэффициент при D_j — средняя разница отклика между уровнем j и базовым при прочих равных. Взаимодействие — произведение признаков $x_1 x_2$ в модели; оно позволяет эффекту одного признака зависеть от значения другого.

ЛОВУШКА

все k индикаторов вместе со свободным членом дают точную мультиколлинеарность (ловушка фиктивных переменных): их сумма равна столбцу единиц.

PYTHON

```
smf.ols('y ~ C(city) + x1 * x2', data=df) # x1 * x2 = x1 + x2 + x1:x2
pd.get_dummies(df, columns=['city'], drop_first=True)
```

СВЯЗИ

[типы данных](#) · [остатки](#) · [линейная регрессия](#)

Логистическая регрессия *logistic regression*

ОПРЕДЕЛЕНИЕ

Модель для бинарного отклика $y \in \{0, 1\}$: вероятность $P(y = 1 | x)$ равна логистической (сигмоидной) функции $\sigma(z) = 1 / (1 + e^{-z})$ от линейной комбинации признаков; линейно по признакам меняется логарифм шансов (логит).

ФОРМУЛЫ

$$P(y = 1 | x) = \sigma(x^\top \beta) = \frac{1}{1 + e^{-x^\top \beta}}, \quad \ln \frac{p}{1-p} = x^\top \beta$$
$$\hat{\beta} = \arg \max_{\beta} \sum_{i=1}^n [y_i \ln p_i + (1 - y_i) \ln(1 - p_i)], \quad p_i = \sigma(x_i^\top \beta) \quad (\text{ММП} \Leftrightarrow \text{минимум log-loss})$$

ПОЯСНЕНИЕ

Закрывшей формулы для $\hat{\beta}$ нет: оптимизируют численно — методом Ньютона (IRLS в statsmodels), L-BFGS или градиентным спуском (sklearn). β_j — изменение логарифма шансов при росте x_j на 1, e^{β_j} — отношение шансов. Класс получают, сравнивая вероятность с порогом (по умолчанию 0,5; порог выбирают под задачу по метрикам классификации). Пример на [рис. 17](#).

PYTHON

```
smf.logit('y ~ x1 + x2', data=df).fit().summary()
LogisticRegression(C=np.inf).fit(X, y) # без штрафа; по умолчанию C=1.0 — L2-регуляризация
```

СВЯЗИ

[отношение шансов](#) · [ММП](#) · [log-loss](#) · [градиентный спуск](#) · [метрики классификации](#) · [StatQuest](#)




Рис. 17. Логистическая регрессия: точки — наблюдения 0 и 1 (сдвинуты по вертикали, чтобы не сливались), кривая — оцененная вероятность $P(y = 1 | x)$.

Шансы и отношение шансов *odds, odds ratio (OR)*

ОПРЕДЕЛЕНИЕ

Шансы события — отношение его вероятности к вероятности противоположного события: $\text{odds} = p / (1 - p)$. Отношение шансов — отношение шансов события в двух группах:
$$\text{OR} = \frac{p_1 / (1 - p_1)}{p_2 / (1 - p_2)}.$$

ПРИМЕР

$p = 0,8$: шансы $0,8 / 0,2 = 4$ («4 к 1»). В логистической регрессии $\beta_1 = 0,4$ означает $\text{OR} = e^{0,4} \approx 1,49$: при росте x на 1 шансы умножаются примерно на 1,5.

ЛОВУШКА

отношение шансов $\neq$ отношение вероятностей (относительный риск $\text{RR} = p_1 / p_2$); они близки только для редких событий: при $p_1 = 0,6$, $p_2 = 0,4$ $\text{RR} = 1,5$, а $\text{OR} = 2,25$.

СВЯЗИ

[логистическая регрессия](#) · [StatQuest](#)

Как измерить эффект изменения так, чтобы вывод был причинным и надёжным.

А/В-тест *A/B test, randomized controlled experiment*

ОПРЕДЕЛЕНИЕ

А/В-тест — рандомизированный контролируемый эксперимент: единицы (пользователи, сессии) случайно распределяют между контрольной группой А (без изменения) и тестовой группой В (с изменением) и сравнивают целевую метрику. Благодаря рандомизации группы в среднем одинаковы по всем факторам, включая ненаблюдаемые, поэтому разницу метрик можно приписать изменению — это оценка среднего эффекта воздействия.

ПОЯСНЕНИЕ

Дизайн фиксируют до старта: гипотезу, основную метрику, α , мощность, MDE, размер выборки и длительность (кратную неделе из-за недельной сезонности). Единица рандомизации должна совпадать с единицей анализа или учитываться в нём. Перед анализом проверяют SRM — соответствие размеров групп плану (критерий согласия χ^2).

ПРИМЕНЕНИЕ

Проверка изменений продукта, цен, рекомендаций, рекламы — везде, где воздействие можно назначить случайно.

PYTHON

```
proportions_ztest(count=[k_b, k_a], nobs=[n_b, n_a]); stats.ttest_ind(b, a, equal_var=False)
stats.chisquare([n_a, n_b]) # проверка SRM при плане 50/50
```

СВЯЗИ

[ATE](#) · [z-критерий для долей](#) · [MDE](#) · [подглядывание](#) · [критерий согласия](#) · [конфаундер](#)

MDE и размер выборки *minimum detectable effect (MDE), sample size, power analysis*

ОПРЕДЕЛЕНИЕ

MDE — наименьший истинный эффект, который тест при заданных α и объёме выборки обнаружит с вероятностью, равной выбранной мощности $1 - \beta$ (обычно 80%). Анализ мощности решает обратную задачу: по α , мощности, MDE δ и дисперсии метрики σ^2 находит необходимый объём выборки.

ФОРМУЛЫ

$$n_{\text{на группу}} = \frac{(z_{1-\alpha/2} + z_{1-\beta})^2 (\sigma_A^2 + \sigma_B^2)}{\delta^2} \approx \frac{2(1,96 + 0,84)^2 \sigma^2}{\delta^2} \approx \frac{16 \sigma^2}{\delta^2}$$
$$\text{MDE} = (z_{1-\alpha/2} + z_{1-\beta}) \sqrt{\frac{\sigma_A^2}{n_A} + \frac{\sigma_B^2}{n_B}}$$

ПОЯСНЕНИЕ

Для конверсии $\sigma^2 = p(1 - p)$. Вдвое меньший MDE требует вчетверо больше данных. Уменьшить нужный объём помогает снижение дисперсии метрики (CUPED).

ПРИМЕР

конверсия 10% ($\sigma^2 = 0,09$), хотим заметить +1 п. п. ($\delta = 0,01$): $n \approx 16 \cdot 0,09 / 0,0001 = 14\,400$ на группу. С дисперсиями обеих групп ($0,1 \cdot 0,9$ и $0,11 \cdot 0,89$) формула даёт $\approx 14\,750$ — столько же, сколько statsmodels.

PYTHON

```
h = proportion_effectsize(0.11, 0.10) # statsmodels.stats.proportion
NormalIndPower().solve_power(effect_size=h, alpha=0.05, power=0.8) # ≈ 14 744
```

СВЯЗИ

[мощность](#) · [размер эффекта](#) · [CUPED](#) · [стандартная ошибка](#) · [StatQuest](#)

Подглядывание *peeking, optional stopping*

ОПРЕДЕЛЕНИЕ

Подглядывание — многократная проверка значимости по ходу эксперимента с остановкой при первом результате $p < \alpha$.

ПОЯСНЕНИЕ

Даже при отсутствии эффекта p-value случайно колеблется и рано или поздно опускается ниже 0,05, поэтому фактическая доля ложноположительных выводов становится намного больше α : при 10 равномерных проверках — около 19%, при 20 — около 25%. Решения: фиксировать размер выборки заранее и анализировать результат один раз либо применять последовательные методы (групповые последовательные планы с границами О'Брайена–Флеминга, always-valid p-value).

СВЯЗИ

[p-value](#) · [MDE](#) · [А/В-тест](#)

Снижение дисперсии: CUPED *CUPED, variance reduction with pre-experiment data*

ОПРЕДЕЛЕНИЕ	CUPED (Controlled-experiment Using Pre-Experiment Data) — поправка метрики Y на ковариату X , измеренную до начала эксперимента и потому не зависящую от воздействия (обычно та же метрика за прошлый период). Оценка эффекта остаётся несмещённой, а её дисперсия уменьшается.
ФОРМУЛЫ	$Y_i^{\text{cuped}} = Y_i - \theta (X_i - \bar{X}), \quad \theta = \frac{\text{cov}(X, Y)}{\text{Var } X}, \quad \text{Var } Y^{\text{cuped}} = (1 - \rho^2) \text{Var } Y$
ПОЯСНЕНИЕ	ρ — корреляция X и Y ; θ оценивают по объединённым данным обеих групп. При $\rho = 0,7$ остаётся 51% дисперсии — для той же мощности нужно примерно вдвое меньше пользователей. CUPED — частный случай регрессионной поправки на ковариату (ANCOVA).
СВЯЗИ	MDE · дисперсия · МНК

Метрики-отношения и дельта-метод *ratio metrics, delta method, linearization*

ОПРЕДЕЛЕНИЕ	Метрика-отношение — отношение двух сумм по пользователям, $R = \sum_i X_i / \sum_i Y_i$ (CTR = клики / показы, средний чек = выручка / заказы), когда единица анализа (показ, заказ) мельче единицы рандомизации (пользователь). Наблюдения одного пользователя зависимы, поэтому наивная формула дисперсии, считающая показы независимыми, обычно её занижает.
ФОРМУЛЫ	$\text{Var}\left(\frac{\bar{X}}{\bar{Y}}\right) \approx \frac{1}{n \mu_Y^2} (\sigma_X^2 - 2R \sigma_{XY} + R^2 \sigma_Y^2), \quad R = \frac{\mu_X}{\mu_Y}$
ПОЯСНЕНИЕ	Формула получена дельта-методом — линейризацией функции $g(\bar{X}, \bar{Y}) = \bar{X} / \bar{Y}$ по Тейлору; n — число пользователей, $\sigma_X^2, \sigma_Y^2, \sigma_{XY}$ — дисперсии и ковариация пользовательских сумм. Альтернативы: бутстрэп по пользователям; линейризация $L_i = X_i - \hat{R} Y_i$ с последующим t-критерием.
СВЯЗИ	независимость · бутстрэп · стандартная ошибка · A/B-тест

9

Временные ряды

этап 9 дорожной карты

Данные, в которых важен порядок: соседние наблюдения зависимы.

Временной ряд и его компоненты *time series: trend, seasonality, decomposition*

ОПРЕДЕЛЕНИЕ	Временной ряд — последовательность наблюдений $y_1, y_2, \dots, y_n$, упорядоченная во времени (обычно с равным шагом). Его раскладывают на тренд T_t (долгосрочное изменение уровня), сезонность S_t (колебания с известным периодом: сутки, неделя, год) и остаток R_t .
ФОРМУЛЫ	$y_t = T_t + S_t + R_t$ (аддитивная модель), $y_t = T_t \cdot S_t \cdot R_t$ (мультипликативная)
ПОЯСНЕНИЕ	Мультипликативную модель берут, когда амплитуда сезонности растёт вместе с уровнем ряда; логарифмирование превращает её в аддитивную. Цикличность (колебания без фиксированного периода) отличают от сезонности. Пример ряда с трендом и недельной сезонностью — на рис. 18 .
PYTHON	<pre>STL(y, period=7).fit() # statsmodels.tsa.seasonal seasonal_decompose(y, model='additive', period=7)</pre>
СВЯЗИ	автокорреляция · стационарность · сглаживание



Рис. 18. Дневной ряд за 12 недель с трендом и недельной сезонностью и его ACF. Серая полоса — $\pm 1,96/\sqrt{n}$ при $n = 84$: автокорреляции внутри неё незначимо отличаются от нуля при $\alpha = 0,05$.

Автокорреляционная функция (ACF) и частная ACF autocorrelation function (ACF), partial ACF

ОПРЕДЕЛЕНИЕ

Автокорреляция на лаге k — корреляция ряда с его копией, сдвинутой на k шагов: $\rho(k) = \text{corr}(y_t, y_{t-k})$; автокорреляционная функция (ACF) — зависимость $\rho(k)$ от лага. Частная автокорреляция (PACF) на лаге k — корреляция y_t и y_{t-k} за вычетом линейного влияния промежуточных значений $y_{t-1}, \dots, y_{t-k+1}$.

ФОРМУЛА

$$r_k = \frac{\sum_{t=k+1}^n (y_t - \bar{y})(y_{t-k} - \bar{y})}{\sum_{t=1}^n (y_t - \bar{y})^2}$$

ПОЯСНЕНИЕ

Для белого шума r_k приближённо распределены как $N(0; 1/n)$, поэтому значения вне полосы $\pm 1,96/\sqrt{n}$ считают значимыми. Пики на лагах 7, 14, 21 в дневных данных — недельная сезонность (рис. 18); медленное затухание ACF — тренд или нестационарность. По ACF и PACF подбирают порядки моделей ARMA.

PYTHON

```
plot_acf(y, lags=30); plot_pacf(y, lags=30) # statsmodels.graphics.tsaplots
acf(y, nlags=30)
```

СВЯЗИ

[корреляция](#) · [стационарность](#) · [временной ряд](#) · [независимость](#)

Стационарность и белый шум (weak) stationarity, white noise, unit root

ОПРЕДЕЛЕНИЕ

Ряд стационарен в широком смысле, если его математическое ожидание и дисперсия постоянны, а ковариация $\text{cov}(y_t, y_{t+k})$ зависит только от лага k , но не от t . Белый шум — ряд ε_t с нулевым средним, постоянной дисперсией σ^2 и некоррелированными значениями.

ФОРМУЛЫ

$E y_t = \mu$, $\text{Var } y_t = \sigma^2$, $\text{cov}(y_t, y_{t+k}) = \gamma(k)$ для всех t ; случайное блуждание: $y_t = y_{t-1} + \varepsilon_t$

ПОЯСНЕНИЕ

Случайное блуждание нестационарно (его дисперсия растёт со временем), но его разности $\Delta y_t = y_t - y_{t-1} = \varepsilon_t$ стационарны. ARMA-модели требуют стационарного ряда; в ARIMA тренд убирают разностями (буква I). Расширенный критерий Дики-Фуллера (ADF) проверяет H_0 : есть единичный корень (ряд нестационарен); критерий KPSS — наоборот, H_0 : ряд стационарен.

ЛОВУШКА

два ряда с трендом часто сильно коррелируют, даже если никак не связаны (ложная регрессия): сравнивайте разности или остатки после удаления тренда.

PYTHON

```
adfuller(y)[1] # p-value критерия ADF; statsmodels.tsa.stattools
kpss(y); np.diff(y)
```

СВЯЗИ

[автокорреляция](#) · [временной ряд](#)

ОПРЕДЕЛЕНИЕ	Скользящее среднее порядка m — среднее m соседних значений ряда; оно сглаживает шум и сезонность с периодом m (рис. 18). Простое экспоненциальное сглаживание — рекуррентная оценка уровня ряда ℓ_t , в которой веса наблюдений экспоненциально убывают с их давностью; прогноз на любой горизонт h равен последнему уровню.
ФОРМУЛЫ	$\ell_t = \alpha y_t + (1 - \alpha) \ell_{t-1}, \quad 0 < \alpha < 1; \quad \hat{y}_{t+h t} = \ell_t$
ПОЯСНЕНИЕ	Чем больше α , тем быстрее модель реагирует на изменения. Методы Хольта и Хольта–Винтерса добавляют тренд и сезонность; семейство ETS (Error, Trend, Seasonal) даёт им статистическую модель и интервалы прогноза.
PYTHON	<pre>y.rolling(7, center=True).mean() ExponentialSmoothing(y, trend='add', seasonal='add', seasonal_periods=7).fit()</pre>
СВЯЗИ	временной ряд · валидация прогноза

Валидация прогноза и метрики точности *time series cross-validation, MAE, RMSE, MAPE, MASE*

ОПРЕДЕЛЕНИЕ	Валидация по времени (backtesting): модель обучают на данных до момента t , прогнозируют следующие h точек, затем сдвигают момент разбиения вперёд и повторяют. Метрики точности сравнивают прогнозы $\hat{y}_t$ с фактическими значениями y_t на тестовых отрезках.
ФОРМУЛЫ	$MAE = \frac{1}{n} \sum y_t - \hat{y}_t , \quad RMSE = \sqrt{\frac{1}{n} \sum (y_t - \hat{y}_t)^2}, \quad MAPE = \frac{100\%}{n} \sum \left \frac{y_t - \hat{y}_t}{y_t} \right , \quad MASE = \frac{MAE}{MAE_{\text{наивн}}}$
ПОЯСНЕНИЕ	n — число прогнозных точек на тестовых отрезках. $MAE_{\text{наивн}}$ — средняя ошибка сезонного наивного прогноза ($\hat{y}_t = y_{t-m}$) на обучающих данных; $MASE < 1$ — модель лучше наивной. Любую модель сравнивайте с простыми прогнозами: наивным (завтра = сегодня) и сезонным наивным. MAPE не определена при $y_t = 0$ и несимметрична.
ЛОВУШКА	обычная кросс-валидация с перемешиванием для рядов недопустима: будущее попадает в обучение (утечка), а соседние точки зависимы.
PYTHON	<pre>TimeSeriesSplit(n_splits=5) # sklearn.model_selection mean_absolute_error(y, y_hat); mean_absolute_percentage_error(y, y_hat) # MAPE — доля, не %</pre>
СВЯЗИ	кросс-валидация · утечка данных · метрики регрессии

А

Причинный вывод

тема А дорожной карты

Как отличить причину от совпадения, когда эксперимент невозможен.

Конфаундер (вмешивающийся фактор) *confounder, confounding*

ОПРЕДЕЛЕНИЕ	Конфаундер — переменная, которая влияет и на воздействие (признак) T , и на результат Y ; она создаёт между T и Y статистическую связь, не являющуюся причинной, или искажает величину причинного эффекта.
ПОЯСНЕНИЕ	Рандомизация устраняет влияние всех конфаундеров, в том числе неизмеренных. В наблюдательных данных учитывают только измеренные: регрессией, стратификацией, сопоставлением (matching), взвешиванием по индексу склонности к воздействию (propensity score).
ПРИМЕР	продажи мороженого коррелируют с числом утоплений; общая причина — жаркая погода. Пользователи, включившие новую функцию, покупают больше, но функцию чаще включают и без того более активные пользователи.
СВЯЗИ	A/B-тест · парадокс Симпсона · линейная регрессия · ATE

Парадокс Симпсона *Simpson's paradox*

ОПРЕДЕЛЕНИЕ

Ситуация, в которой связь, наблюдаемая в каждой подгруппе, исчезает или меняет направление при объединении подгрупп. Возможна, только если переменная, задающая подгруппы, связана и с группой (воздействием), и с результатом. Какой вывод верен, решает причинная структура: если эта переменная — конфаундер, верен вывод по подгруппам; если медиатор (звено на пути от воздействия к результату) — по объединённым данным (для полного эффекта).

ТАБЛИЦА

Успех лечения	Лечение А	Лечение В
мелкие камни	93% (81 из 87)	87% (234 из 270)
крупные камни	73% (192 из 263)	69% (55 из 80)
все пациенты	78% (273 из 350)	83% (289 из 350)

Классический пример: Charig et al., BMJ, 1986 — лечение камней в почках.

ПРИМЕР

лечение А успешнее в каждой подгруппе, но хуже в целом: его чаще назначали при крупных камнях, где успех реже (263 из 350 пациентов группы А против 80 из 350 в группе В). Размер камня влияет и на выбор лечения, и на исход — это конфаундер, поэтому верен вывод по подгруппам: А лучше.

СВЯЗИ

конфаундер

Средний эффект воздействия (ATE) *average treatment effect (ATE), potential outcomes*

ОПРЕДЕЛЕНИЕ

В модели потенциальных исходов у объекта i два исхода: $Y_i(1)$ — при воздействии и $Y_i(0)$ — без него; индивидуальный эффект $\tau_i = Y_i(1) - Y_i(0)$. Средний эффект воздействия — математическое ожидание индивидуального эффекта по совокупности.

ФОРМУЛЫ

$ATE = E[Y(1) - Y(0)]$; при рандомизации: $ATE = E[Y | T = 1] - E[Y | T = 0]$

ПОЯСНЕНИЕ

У каждого объекта наблюдается только один из двух исходов (фундаментальная проблема причинного вывода), поэтому АТЕ оценивают по группам. Без рандомизации простая разность средних смещена из-за конфаундеров; применяют сопоставление (matching), взвешивание по индексу склонности к воздействию (propensity score) $e(x) = P(T = 1 | x)$, разность разностей, инструментальные переменные.

СВЯЗИ

А/В-тест · разность разностей · конфаундер

Разность разностей *difference-in-differences (DiD)*

ОПРЕДЕЛЕНИЕ

Оценка эффекта воздействия как разности изменений среднего результата в группе воздействия (T) и в контрольной группе (C) за один и тот же период — до и после воздействия.

ФОРМУЛА

$\hat{\tau}_{DiD} = (\bar{y}_{T, \text{после}} - \bar{y}_{T, \text{до}}) - (\bar{y}_{C, \text{после}} - \bar{y}_{C, \text{до}})$

ПРИМЕР

после запуска рекламы продажи в городах с рекламой выросли на 12%, в остальных — на 5%: эффект ≈ 7 п. п. дополнительного прироста. Для относительного эффекта DiD считают по логарифму продаж: $\ln 1,12 - \ln 1,05 \approx 0,0645$, откуда относительный эффект $e^{0,0645} - 1 = 1,12/1,05 - 1 \approx 6,7\%$.

ЛОВУШКА

ключевое предположение — параллельные тренды: без воздействия группы менялись бы одинаково. Проверяют его по динамике до воздействия.

PYTHON

```
smf.ols('y ~ treated * post', data=df).fit() # коэффициент treated:post — оценка DiD
```

СВЯЗИ

ATE · конфаундер

Параметр считается случайной величиной, а данные обновляют знания о нём.

Априорное и апостериорное распределения *prior $\pi(\theta)$, posterior $\pi(\theta | x)$, conjugate prior*

ОПРЕДЕЛЕНИЕ

В байесовском подходе параметр θ считают случайной величиной. Априорное распределение $\pi(\theta)$ описывает знания о параметре до наблюдений, апостериорное $\pi(\theta | x)$ — после них; апостериорное вычисляют по формуле Байеса из априорного и правдоподобия.

ФОРМУЛЫ

$$\pi(\theta | x) = \frac{L(\theta; x) \pi(\theta)}{\int L(\theta'; x) \pi(\theta') d\theta'} \propto L(\theta; x) \pi(\theta)$$

$$\text{Beta}(a, b) \text{ и } k \text{ успехов из } n \Rightarrow \text{Beta}(a + k, b + n - k), \quad E(\theta | x) = \frac{a + k}{a + b + n}$$

ПОЯСНЕНИЕ

Если апостериорное распределение принадлежит тому же семейству, что и априорное, априорное называют сопряжённым (Beta — для биномиальных данных, Gamma — для пуассоновских). В общем случае апостериорное распределение получают численно — методами MCMC (PyMC, Stan).

ПРИМЕР

конверсия: априорное Beta(1; 1) (равномерное), наблюдали 30 покупок из 200 — апостериорное Beta(31; 171) со средним $31/202 \approx 0,153$ (рис. 19).

PYTHON

```
post = stats.beta(1 + k, 1 + n - k); post.mean(); post.interval(0.95)
```

СВЯЗИ

[формула Байеса](#) · [правдоподобие](#) · [байесовский интервал](#) · [► Seeing Theory](#)



Рис. 19. Байесовское обновление: равномерное априорное распределение конверсии после 30 покупок из 200 превращается в апостериорное Beta(31; 171); закрашен 95%-й интервал.

Байесовский (достоверный) интервал *credible interval*

ОПРЕДЕЛЕНИЕ

Интервал $[a; b]$, в котором параметр лежит с заданной апостериорной вероятностью: $P(a \leq \theta \leq b | x) = 1 - \alpha$. Обычно берут интервал между квантилями уровней $\alpha/2$ и $1 - \alpha/2$ апостериорного распределения или интервал наибольшей апостериорной плотности (HPD).

ПОЯСНЕНИЕ

В отличие от доверительного интервала допускает прямую вероятностную формулировку, но зависит от априорного распределения. При большом n и неинформативном априорном оба интервала численно близки.

ПРИМЕР

для Beta(31; 171) 95%-й интервал $\approx [0,107; 0,206]$: «с вероятностью 95% конверсия в этих пределах» — при выбранном априорном распределении.

PYTHON

```
stats.beta(31, 171).interval(0.95)
```

СВЯЗИ

[доверительный интервал](#) · [апостериорное распределение](#)

Качество модели на новых данных, метрики регрессии и классификации и их неопределённость.

Компромисс смещения и разброса *bias-variance tradeoff, underfitting, overfitting*

ОПРЕДЕЛЕНИЕ

Разложение ожидаемой квадратичной ошибки прогноза в точке x (по случайным обучающим выборкам и шуму) на квадрат смещения, дисперсию модели и неустраняемый шум. Простые модели имеют большое смещение (недообучение), сложные — большую дисперсию (переобучение).

ФОРМУЛА

$$E[(y - \hat{f}(x))^2] = (E\hat{f}(x) - f(x))^2 + \text{Var} \hat{f}(x) + \sigma_\varepsilon^2$$

ПОЯСНЕНИЕ

Ошибка на обучающей выборке с ростом сложности только падает, а на новых данных — сначала падает, потом растёт (рис. 20). Сложность подбирают по валидации или кросс-валидации; регуляризация и ансамбли уменьшают дисперсию.

СВЯЗИ

[свойства оценок](#) · [регуляризация](#) · [кросс-валидация](#) · [StatQuest](#)




Рис. 20. Компромисс смещения и разброса (схема): с ростом сложности ошибка на обучающей выборке падает, а на новых данных — сначала падает, потом растёт.

Кросс-валидация (скользящий контроль) *cross-validation (k-fold CV)*

ОПРЕДЕЛЕНИЕ

Метод оценки качества модели на новых данных: выборку делят на k частей (фолдов); k раз модель обучают на $k - 1$ частях и вычисляют метрику M_j на оставшейся; оценка качества — среднее $\bar{M} = \frac{1}{k} \sum_{j=1}^k M_j$.

ПОЯСНЕНИЕ

Обычно $k = 5$ или 10 ; стратифицированная CV сохраняет доли классов в фолдах. Разброс M_j показывает нестабильность оценки. Вся предобработка (масштабирование, отбор признаков, заполнение пропусков) должна выполняться внутри фолдов (Pipeline), иначе будет утечка; для временных рядов — только разбиение по времени, для зависимых наблюдений — по группам (GroupKFold).

PYTHON

```
cross_val_score(make_pipeline(StandardScaler(), model), X, y, scoring='roc_auc',
                 cv=StratifiedKFold(n_splits=5, shuffle=True, random_state=0))
```

СВЯЗИ

[утечка данных](#) · [валидация прогноза](#) · [неопределённость метрики](#) · [смещение и разброс](#) · [StatQuest](#)

Утечка данных *data leakage, target leakage*

ОПРЕДЕЛЕНИЕ

Утечка данных — попадание в обучение информации, недоступной в момент применения модели: значений из будущего, признаков, вычисленных с использованием целевой переменной, или статистик, посчитанных по всему датасету вместе с тестовой частью.

ПОЯСНЕНИЕ

Утечка даёт завышенное качество на валидации и провал в эксплуатации. Типичные источники: масштабирование или заполнение пропусков до разбиения на обучение и тест; дубликаты объектов в обеих частях; признаки вроде «дата закрытия заявки» при прогнозе её одобрения. Подозрительно сильный признак — первый кандидат на проверку.

СВЯЗИ

[кросс-валидация](#) · [валидация прогноза](#)

Метрики качества регрессии regression metrics: MAE, MSE, RMSE, MAPE, R²

ОПРЕДЕЛЕНИЕ Метрики регрессии — функции, сравнивающие прогнозы $\hat{y}_i$ с фактическими значениями y_i на тестовой выборке; чем меньше ошибка (или ближе R^2 к 1), тем лучше.

ФОРМУЛЫ
$$\text{MAE} = \frac{1}{n} \sum |y_i - \hat{y}_i|, \quad \text{MSE} = \frac{1}{n} \sum (y_i - \hat{y}_i)^2, \quad \text{RMSE} = \sqrt{\text{MSE}}, \quad \text{MAPE} = \frac{100\%}{n} \sum \left| \frac{y_i - \hat{y}_i}{y_i} \right|$$

Метрика	Особенности	Когда использовать
MAE	в единицах y ; устойчива к выбросам; минимизируется медианой	все ошибки одинаково «дороги», в данных есть выбросы
MSE, RMSE	MSE — в квадратах единиц, RMSE — в единицах y ; сильно штрафуют большие ошибки; минимизируются средним	крупные ошибки особенно нежелательны; функция потерь МНК
MAPE	в процентах; не определена при $y = 0$; несимметрична (занижение штрафует слабее)	сравнение рядов разного масштаба при y , далёких от нуля
R ²	доля объяснённой дисперсии; сравнение с константой $\bar{y}$; на тесте может быть < 0	объясняющая сила модели; сравнение моделей на одних данных

ЛОВУШКА метрика на тестовой выборке — оценка со случайной ошибкой; сравнивайте модели на одних и тех же объектах и с учётом неопределённости (статья «Неопределённость метрики»).

PYTHON

```
mean_absolute_error(y, y_hat); mean_squared_error(y, y_hat) # sklearn.metrics
root_mean_squared_error(y, y_hat); r2_score(y, y_hat)
mean_absolute_percentage_error(y, y_hat) # MAPE как доля: 0.12, а не 12%
```

СВЯЗИ [R²](#) · [валидация прогноза](#) · [неопределённость метрики](#)

Матрица ошибок и метрики классификации confusion matrix, accuracy, precision, recall, specificity, F1

ОПРЕДЕЛЕНИЕ Матрица ошибок — таблица, в которой для бинарного классификатора при выбранном пороге подсчитаны истинно положительные (TP), ложноположительные (FP), ложноотрицательные (FN) и истинно отрицательные (TN) ответы. Метрики классификации — функции этих четырёх чисел.

	Прогноз: 1 (положительный)	Прогноз: 0 (отрицательный)
Факт: 1	TP — истинно положительный	FN — ложноотрицательный (ошибка II рода)
Факт: 0	FP — ложноположительный (ошибка I рода)	TN — истинно отрицательный

ФОРМУЛЫ
$$\text{accuracy} = \frac{TP + TN}{TP + TN + FP + FN}, \quad \text{precision} = \frac{TP}{TP + FP}$$
$$\text{recall} = \text{TPR} = \frac{TP}{TP + FN}, \quad \text{specificity} = \frac{TN}{TN + FP}, \quad \text{FPR} = \frac{FP}{FP + TN} = 1 - \text{specificity}$$
$$F_1 = \frac{2 \cdot \text{precision} \cdot \text{recall}}{\text{precision} + \text{recall}}, \quad F_\beta = \frac{(1 + \beta^2) \cdot \text{precision} \cdot \text{recall}}{\beta^2 \cdot \text{precision} + \text{recall}}$$

ПРИМЕНЕНИЕ Precision — когда дороги ложные срабатывания (спам-фильтр, блокировка платежа); recall — когда дорог пропуск (скрининг болезни, мошенничество); F_1 — баланс двух, F_β с $\beta > 1$ сильнее ценит recall. Accurasy годится только для сбалансированных классов с одинаковой ценой ошибок.

ПРИМЕР 1 000 транзакций, из них 50 мошеннических. Модель отметила 60, из них 40 действительно мошеннические: TP = 40, FP = 20, FN = 10, TN = 930. Precision = 40/60 ≈ 0,67, recall = 40/50 = 0,80, $F_1 \approx 0,73$, accuracy = 970/1000 = 0,97. Модель «все транзакции честные» имеет accuracy 0,95 при нулевом recall.

ЛОВУШКА все эти метрики зависят от порога; сравнивая модели, фиксируйте порог или используйте не зависящие от порога ROC-AUC и PR-AUC. В русских текстах «точностью» называют и precision, и accuracy — уточняйте, о какой метрике речь.

PYTHON

```
confusion_matrix(y_true, y_pred); classification_report(y_true, y_pred)
precision_recall_fscore_support(y_true, y_pred, average='binary') # sklearn.metrics
```

СВЯЗИ [ROC-AUC](#) · [log-loss](#) · [неопределённость метрики](#) · [тепловая карта](#)

ROC-кривая, ROC-AUC и PR-кривая ROC curve, ROC-AUC, precision-recall curve, average precision (AP)

ОПРЕДЕЛЕНИЕ

ROC-кривая — множество точек $(FPR(t), TPR(t))$ для всех порогов t классификатора с оценками $s(x)$, где $FPR = FP / (FP + TN)$. ROC-AUC — площадь под ней; она равна вероятности того, что случайный положительный объект получит оценку выше случайного отрицательного. PR-кривая — точки (recall, precision) по всем порогам; площадь под ней оценивают средней точностью (AP).

ФОРМУЛА

$$AUC = P(s(x^+) > s(x^-)) + \frac{1}{2} P(s(x^+) = s(x^-))$$

ПОЯСНЕНИЕ

ROC-AUC не зависит от порога и от доли классов: 0,5 — случайное ранжирование, 1 — идеальное. При редком положительном классе ROC-AUC может быть высокой при низкой precision; PR-кривая и AP чувствительнее — их базовый уровень равен доле положительных. На рис. 21 при 5% положительных модели А и В имеют ROC-AUC 0,95 и 0,79, а AP — 0,66 и 0,19.

ПРИМЕНЕНИЕ

Сравнение ранжирующей способности моделей (скоринг, отток, модерация); выбор порога по кривой под нужную precision или recall.

PYTHON

```
roc_auc_score(y, scores); roc_curve(y, scores)
average_precision_score(y, scores); precision_recall_curve(y, scores) # sklearn.metrics
```

СВЯЗИ

[метрики классификации](#) · [логистическая регрессия](#) · [неопределённость метрики](#)




Рис. 21. ROC- и PR-кривые двух моделей на 5 000 объектах, из которых 5% положительные. ROC-кривая модели В выглядит прилично, но PR-кривая показывает низкую precision.

Log-loss, энтропия и KL-дивергенция log-loss (cross-entropy), entropy, Kullback-Leibler divergence

ОПРЕДЕЛЕНИЕ

Log-loss (бинарная кросс-энтропия) — среднее значение минуса логарифма вероятности, которую модель присвоила фактическому классу. Энтропия $H(p)$ — мера неопределённости распределения p ; кросс-энтропия $H(p, q)$ — средние потери, если данные распределены по p , а модель предсказывает q ; KL-дивергенция — разность $H(p, q) - H(p)$, «лишние» потери от использования q вместо p .

ФОРМУЛЫ

$$\text{log-loss} = -\frac{1}{n} \sum_{i=1}^n [y_i \ln \hat{p}_i + (1 - y_i) \ln (1 - \hat{p}_i)]$$

$$H(p) = -\sum_k p_k \ln p_k, \quad H(p, q) = -\sum_k p_k \ln q_k, \quad \text{KL}(p \parallel q) = \sum_k p_k \ln \frac{p_k}{q_k} = H(p, q) - H(p) \geq 0$$

ПОЯСНЕНИЕ

Log-loss оценивает качество вероятностей, а не только ранжирования: уверенная ошибка ($\hat{p} = 0,99$ при $y = 0$) стоит $-\ln 0,01 \approx 4,6$. Минимизация log-loss равносильна ММП для логистической регрессии. KL несимметрична: $\text{KL}(p \parallel q) \neq \text{KL}(q \parallel p)$.

PYTHON

```
log_loss(y_true, p_pred) # sklearn.metrics; stats.entropy(p); stats.entropy(p, q) # KL(p||q)
```

СВЯЗИ

[ММП](#) · [логистическая регрессия](#) · [метрики классификации](#) · [StatQuest](#)

Неопределённость метрики и сравнение моделей

confidence interval for a metric, McNemar's test, paired bootstrap

ОПРЕДЕЛЕНИЕ

Метрика на тестовой выборке — статистика, то есть оценка качества модели на генеральной совокупности, и у неё есть стандартная ошибка. Для доли верных ответов на n объектах $SE \approx \sqrt{\text{acc}(1 - \text{acc})/n}$; для сложных метрик (ROC-AUC, F_1) SE и доверительные интервалы получают бутстрэпом по объектам.

ФОРМУЛА

$$\chi^2_{\text{Мак-Немар}} = \frac{(b - c)^2}{b + c} \overset{a}{\sim} \chi^2(1) \text{ при } H_0$$

ПОЯСНЕНИЕ

Модели сравнивают на одних и тех же объектах парными методами. Критерий Мак-Немара учитывает только объекты, где модели расходятся: b — верный ответ только у первой, c — только у второй. Парный бутстрэп выбирает объекты с возвращением и на каждой бутстрэп-выборке считает разность метрик.

ПРИМЕР

$n = 1000$, accuracy = 0,90: SE $\approx 0,0095$, 95%-й ДИ Вальда $\approx [0,881; 0,919]$, Уилсона — $[0,880; 0,917]$. Разница моделей в 0,5 п. п. намного меньше ширины интервала; значима ли она, решает только парное сравнение на тех же объектах.

PYTHON

```
proportion_confint(k, n, method='wilson')
mcnemar([[n11, b], [c, n00]], exact=False, correction=False) # как формула выше; statsmodels
```

СВЯЗИ

[доверительный интервал](#) · [бутстрэп](#) · [кросс-валидация](#) · [метрики классификации](#)



По-русски

А		критерий знаковых рангов	20
автокорреляция (ACF)	30	Уилкоксона	
аксиомы Колмогорова	8	критерий Колмогорова–Смирнова	22
альтернативная гипотеза	16	критерий Краскела–Уоллиса	21
анализ мощности	28	критерий Мак–Немара	37
апостериорная вероятность	9	критерий Манна–Уитни	20
апостериорное распределение	33	критерий согласия χ^2	22
априорная вероятность	9	критерий Тьюки	21
априорное распределение	33	критерий Уэлча	19
асимметрия	5	критерий хи-квадрат (χ^2)	22
Б		независимости	
байесовский (достоверный)	33	критерий Шапиро–Уилка	19
интервал		критическая область	17
белый шум	30	критическое значение	17
бимодальное распределение	3	кросс-валидация (скользящий	34
бутстрэп	16	контроль)	
В		кросс-энтропия	36
валидация по времени (backtesting)	31	Л	
вариационный ряд	3	лаг	30
вероятность	8	лассо (lasso)	26
взаимодействие признаков	27	линеаризация	29
взвешенное среднее	3	линейная регрессия	23
внутригрупповая изменчивость	21	логарифм правдоподобия	14
временной ряд	29	логистическая регрессия	27
выборка	2	логит	27
выборочное распределение	12	ложная регрессия	30
выброс	5	М	
Г		математическое ожидание	10
генеральная совокупность	2	матрица ошибок	35
гетероскедастичность	26	медиана	3
гистограмма	6	медианное абсолютное отклонение	4
градиентный спуск	24	(MAD)	
гребневая регрессия (ridge)	26	межгрупповая изменчивость	21
Д		межквартильный размах (IQR)	4
декомпозиция ряда	29	метод Бенджамини–Хошберга	20
дельта-метод	29	метод максимального	15
диаграмма размаха	6	правдоподобия (ММП)	
дискретный / непрерывный	2	метод моментов	15
дисперсионный анализ (ANOVA)	21	метод наименьших квадратов	24
дисперсия	4	(МНК)	
дисперсия случайной величины	10	метод Холма	20
доверительный интервал (ДИ)	15	метод Хольта–Винтерса	31
достигаемый уровень значимости	17	метрика-отношение	29
З		метрики регрессии	35
закон больших чисел (ЗБЧ)	12	минимальный обнаруживаемый	28
значимость коэффициентов	25	эффект (MDE)	
регрессии		множественные сравнения	20
И		мода	3
индекс склонности к воздействию	32	мощность критерия	18
(propensity score)		мультиколлинеарность	26
интервал Уилсона	15	Н	
К		наивный прогноз	31
категориальный признак	2	недообучение	34
квантиль	4	независимость	9
квартиль	4	некоррелированность	9
ковариационная матрица	6	неопределённость метрики	37
ковариация	6	непараметрический критерий	20
количественный признак	2	неравенство Чебышёва	4
компромисс смещения и разброса	34	несмещённость	14
контрольная группа	28	номинальная шкала	2
конфаундер (вмешивающийся	31	нормальные уравнения	24
фактор)		нулевая гипотеза	16
корреляционная матрица	7	О	
корреляция Кендалла	7	одновыборочный t-критерий	19
корреляция Пирсона	6	односторонняя / двусторонняя	16
корреляция Спирмена	7	альтернатива	
корреляция $\neq$ причинность	31	остатки	26
коэффициент вариации	4	остаточная сумма квадратов (RSS)	24
коэффициент детерминации (R^2)	25	отклик (зависимая переменная)	23
коэффициент корреляции	6	относительный риск	27
критерий KPSS	30	отношение шансов	27
критерий Бруннера–Мюнцеля	20	оценка максимального	15
критерий Дики–Фуллера,	30	правдоподобия (ОМП)	
расширенный (ADF)		ошибка I рода	18
		ошибка II рода	18
		ошибка игрока	12

In English

6		Е	
68–95–99.7 rule	4	effect size	18
A		efficiency	14
A/B test	28	elastic net	26
accuracy	35	entropy	36
adjusted R^2	25	estimate	14
alternative hypothesis	16	estimator	14
analysis of variance	21	eta squared	18
(ANOVA)		event	8
augmented Dickey–Fuller	30	expected value, expectation	10
test (ADF)		exponential smoothing	31
autocorrelation function	30	F	
(ACF)		F-distribution	13
average precision (AP)	36	F1 score	35
average treatment effect	32	false discovery rate (FDR)	20
(ATE)		family-wise error rate	20
B		(FWER)	
backtesting	31	Fisher's exact test	22
Bayes' theorem	9	fold	34
Benjamini–Hochberg	20	G	
procedure		gambler's fallacy	12
Bessel's correction	4	Gauss–Markov theorem	24
between-group variability	21	goodness-of-fit test	22
bias	14	gradient descent	24
bias–variance tradeoff	34	H	
bimodal distribution	3	heatmap	7
Bonferroni correction	20	heavy tails	5
bootstrap	16	heteroscedasticity	26
box plot	6	histogram	6
Brunner–Munzel test	20	Holm method	20
C		Holt–Winters method	31
categorical variable	2	HPD interval	33
central limit theorem (CLT)	12	hypothesis testing	17
Chebyshev's inequality	4	procedure	
chi-squared distribution	13	I	
chi-squared test of	22	independence	9
independence		interaction	27
coefficient of determination	25	interquartile range (IQR)	4
(R^2)		K	
coefficient of variation (CV)	4	k-fold	34
coefficient t-test	25	Kendall's tau	7
Cohen's d	18	Kolmogorov axioms	8
condition number	24	Kolmogorov–Smirnov test	22
conditional probability	8	KPSS test	30
confidence interval (CI)	15	Kruskal–Wallis test	21
confidence level	15	Kullback–Leibler divergence	36
confounder	31	kurtosis	5
confounding	31	L	
confusion matrix	35	lag	30
conjugate prior	33	lasso	26
consistency	14	law of large numbers (LLN)	12
contingency table	22	law of total probability	8
control group	28	learning rate	24
Cook's distance	26	likelihood	14
correlation coefficient	6	linear regression	23
correlation matrix	7	linearization	29
covariance	6	log-likelihood	14
covariance matrix	6	log-loss	36
Cramér's V	18	logistic regression	27
credible interval	33	logit, log-odds	27
critical region	17	M	
critical value	17	Mann–Whitney U test	20
cross-entropy	36	MAPE	31
cross-validation	34	MASE	31
cumulative distribution	9	matching	32
function (CDF)		maximum likelihood	15
CUPED	29	estimation (MLE)	
D		MCMC	33
data leakage	34	McNemar's test	37
decomposition	29	mean	3
degrees of freedom (df)	14	mean absolute error (MAE)	35
delta method	29	mean squared error (MSE)	14
difference-in-differences	32	median	3
(DiD)		median absolute deviation	4
discrete / continuous	2	(MAD)	
dummy variable	27		

П		Т		method of moments	15	residuals	26
парадокс Симпсона	32	таблица сопряжённости	22	metric confidence interval	37	response (dependent variable)	23
параллельные тренды	32	теорема Гаусса–Маркова	24	minimum detectable effect (MDE)	28	ridge regression	26
параметр	11	тепловая карта	7	mode	3	risk ratio (RR)	27
парный t-критерий	19	тестовая группа	28	moving average	31	robust (HC) standard errors	25
парный бутстрэп	37	точечная оценка	14	multicollinearity	26	ROC curve	36
переобучение	34	точный критерий Фишера	22	multiple comparisons	20	ROC-AUC	36
перестановочный тест	20	тренд	29			root mean squared error (RMSE)	35
перцентиль	4	тяжёлые хвосты	5	N		S	
плотность распределения	9	У		naive forecast	31	sample	2
подглядывание (peeking)	28	уровень доверия	15	nominal scale	2	sample ratio mismatch (SRM)	22
поправка Бесселя	4	уровень значимости α	17	nonparametric test	20	sample size	28
поправка Бонферрони	20	усечённое среднее	3	normal equations	24	sample space	8
поправка Йейтса	22	условная вероятность	8	normality test	19	sampling distribution	12
порядковая шкала	2	утечка данных	34	null hypothesis	16	seasonality	29
последовательное тестирование	28	Ф		numerical variable	2	selection bias	2
потенциальные исходы	32	фиктивная переменная	27	O		sequential testing	28
правило трёх сигм	4	фолд	34	odds	27	Shapiro–Wilk test	19
правило Тьюки	5	формула Байеса	9	odds ratio (OR)	27	sigmoid (logistic) function	27
предиктор (признак)	23	формула полной вероятности	8	one-hot encoding	27	significance level	17
предположения линейной регрессии	23	функция правдоподобия	14	one-sample t-test	19	simple random sample	2
признак (переменная)	2	функция распределения	9	one-sided / two-sided test	16	Simpson's paradox	32
проверка нормальности	19	Ц		optional stopping	28	skewness	5
простая случайная выборка	2	центральная предельная теорема (ЦПТ)	12	order statistics	3	Spearmen correlation	7
пространство элементарных исходов	8	Ч		ordinal scale	2	specificity	35
Р		частная автокорреляция (PACF)	30	ordinary least squares (OLS)	24	spurious regression	30
размах	4	число обусловленности	24	outlier	5	standard deviation (SD)	4
размер выборки	28	число степеней свободы	14	overfitting	34	standard error (SE)	13
размер эффекта	18	Ш		P		standardization	13
разность разностей (DiD)	32	шаг обучения (learning rate)	24	p-hacking	17	stationarity	30
ранг	7	шансы	27	p-value	17	statistic	11
рандомизация	28	шкала отношений	2	paired bootstrap	37	statistical hypothesis	16
распределение Стьюдента (t)	13	Э		paired t-test	19	statistical power	18
распределение Фишера (F)	13	экспоненциальное сглаживание	31	parallel trends	32	statistical significance	17
распределение хи-квадрат (χ^2)	13	экссесс	5	parameter	11	statistical test	17
расстояние Кука	26	эластичная сеть	26	partial autocorrelation (PACF)	30	stochastic gradient descent (SGD)	24
регуляризация	26	энтропия	36	Pearson correlation	6	Student's t-distribution	13
робастные стандартные ошибки	25	эффективность оценки	14	peeking	28	Student's t-test	19
ряд распределения	9	Я		percentile	4	T	
С		ящик с усами	6	permutation test	20	target leakage	34
сводная таблица	7	A–Z		pivot table	7	test statistic	17
свойства дисперсии	10	η^2 (эта-квадрат)	18	population	2	time series	29
сезонность	29	A/B-тест	28	posterior distribution	33	time series cross-validation	31
сигмоида	27	accuracy (доля верных ответов)	35	posterior probability	9	treatment group	28
скользящее среднее	31	CUPED	29	potential outcomes	32	trend	29
скорректированный R^2	25	d Коэна	18	power analysis	28	trimmed mean	3
случайная величина	9	F-критерий для регрессии	25	precision	35	Tukey's fences	5
случайное блуждание	30	F1-мера	35	precision-recall curve	36	Tukey's HSD	21
смещение отбора	2	FDR	20	predictor (regressor)	23	two-proportion z-test	19
смещение оценки	14	FWER	20	prior distribution	33	type I error (false positive)	18
снижение дисперсии	29	HPD-интервал	33	prior probability	9	type II error (false negative)	18
событие	8	KL-дивергенция	36	probability	8	U	
сопоставление (matching)	32	log-loss	36	probability density function (PDF)	9	unbiasedness	14
сопряжённое априорное состояние	33	MAE (средняя абсолютная ошибка)	35	probability mass function (PMF)	9	uncorrelated	9
специфичность	35	MAPE	31	propensity score	32	underfitting	34
среднее арифметическое	3	MASE	31	Q		V	
среднеквадратичная ошибка (MSE)	34	MCMC	33	quantile	4	variable, feature	2
средний эффект воздействия (ATE)	12	MSE, RMSE	35	quartile	4	variance	4
средняя точность (AP)	36	one-hot кодирование	27	Q–Q plot	19	variance inflation factor (VIF)	26
стандартизация	13	p-hacking	17	R		variance of a random variable	10
стандартная ошибка (SE)	13	p-value (p-значение)	17	random variable	9	variance reduction	29
стандартное отклонение	4	PR-кривая	36	random walk	30	W	
статистика критерия	17	precision (точность)	35	randomization	28	weighted mean	3
статистическая гипотеза	16	QQ-график	19	range	4	Welch's t-test	19
статистическая значимость	17	recall (полнота)	35	rank	7	white noise	30
статистический критерий	17	ROC-AUC	36	ratio metric	29	Wilcoxon signed-rank test	20
стационарность	30	ROC-кривая	36	ratio scale	2	Wilson interval	15
стохастический градиентный спуск (SGD)	24	SRM (перекос групп)	22	recall (sensitivity, TPR)	35	within-group variability	21
схема проверки гипотезы	17	t-критерий Стьюдента	19	regression F-test	25	Y	
		V Крамера	18	regression metrics	35	Yates's correction	22
		VIF	26	regularization	26	Z	
		z-критерий для долей	19	resampling	16	z-score	13
		z-оценка	13	residual sum of squares (RSS)	24		